

Predicción de la deserción universitaria en EAFIT con aprendizaje de máquina (noviembre de 2025)

Santiago Giraldo Ramírez
Universidad EAFIT
Medellín, Colombia
Sgiraldor2@eafit.edu.co

María Paula Castro Hoyos
Universidad EAFIT
Medellín, Colombia
mpcastroh@eafit.edu.co

Magda Carolina Rodríguez Rusinque
Universidad EAFIT
Medellín, Colombia
mcrodrigur@eafit.edu.co

Resumen – La deserción universitaria en Colombia y América Latina sigue siendo un desafío con causas académicas, sociales y económicas. Este estudio, basado en datos reales y anonimizados de la Universidad EAFIT (2000–2025), analiza factores académicos y socioeconómicos mediante técnicas de *machine learning* supervisado para predecir la deserción estudiantil. Se desarrollan modelos predictivos y un sistema de alerta temprana orientado a identificar estudiantes con alta probabilidad de abandono, facilitando intervenciones oportunas. La investigación integra rigor metodológico y aplicabilidad práctica, aportando una solución replicable para fortalecer la retención estudiantil.

Palabras claves: deserción universitaria, análisis predictivo, factores económicos, rendimiento académico, Universidad EAFIT, Machine Learning.

Abstract – University dropout rates in Colombia and Latin America continue to be a challenge with academic, social, and economic causes. Evidence indicates that early academic performance is the strongest predictor of dropout, and that socioeconomic factors such as social class, parental education, and income, among others, are directly related to dropout rates. This case study is based on real, anonymized data from EAFIT University in Medellín from 2000 to 2025. It integrates both dimensions to build machine learning models and an early warning system using supervised learning techniques. The objective is to promptly identify those most likely to drop out, so that timely interventions can be provided to these students. This contribution combines methodological rigor and practical utility, offering a real and replicable solution to improve student retention.

Keywords: deserción universitaria, análisis predictivo, factores económicos, rendimiento académico, Universidad EAFIT, Machine Learning.

I. INTRODUCCIÓN

La deserción universitaria en Colombia y América Latina sigue siendo un reto con causas académicas, sociales y económicas. La evidencia señala que el rendimiento académico temprano es el predictor más sólido del abandono y que factores socioeconómicos como el estrato, escolaridad de los padres, ingresos, entre otros, están relacionados directamente con la

deserción. Este caso de estudio está basado en datos reales anonimizados de la Universidad EAFIT, Medellín desde el año 2000 hasta 2025; e integra ambas dimensiones para construir modelos de Machine Learning y un esquema de alertas tempranas empleando técnicas de aprendizaje supervisado. El objetivo es identificar oportunamente a quienes presentan mayor probabilidad de desertar, para que posteriormente se pueda realizar una intervención oportuna a esos estudiantes. El aporte combina rigor metodológico y utilidad práctica, ofreciendo una solución real y replicable para mejorar la permanencia estudiantil.

II. ESTADO DEL ARTE

A. Panorama de la deserción universitaria en Colombia y América Latina

La deserción universitaria en Colombia y Latinoamérica es un caso de estudio constante y dinámico, que ha sido ampliamente documentado en la literatura académica. Las investigaciones regionales identifican cinco factores principales que influyen en la decisión de abandonar los estudios: individual, académico, económico, institucional y cultural [1,2]. Los factores académico y socioeconómico emergen consistentemente como determinantes críticos para la decisión de abandonar estudios universitarios.

Informes institucionales y ministeriales en Colombia reportan tasas históricas de abandono entre 44.9% y 56% en diferentes períodos estudiados [6]. En tanto, estudios universitarios locales estiman que aproximadamente la mitad de quienes ingresan no completan la carrera [7, 8]

B. Factores académicos predictivos

El rendimiento académico temprano emerge como el predictor más robusto de deserción. Los estudios identifican variables académicas clave:

- Rendimiento en primeras semanas/primer semestre: Predictor fuerte de permanencia [9]
- Puntaje en pruebas de ingreso: Correlación con éxito académico posterior

- Resultados en matemáticas: Área crítica para múltiples carreras
- Adaptación académica: Transición de educación secundaria a universitaria

C. Factores socioeconómicos determinantes

Con respecto a las características socioeconómicas, los estudios de carácter nacional [11] refieren como factores de riesgo: nivel familiar de ingresos; el nivel educativo de los padres (la diferencia de riesgo entre un estudiante cuya madre tiene como máximo nivel educativo primaria y una con nivel universitario es de 10 puntos); el estrato socioeconómico, situación laboral; método de financiación; costos asociados; entre otros.

Por ejemplo, un estudiante que trabajaba al momento de presentar las pruebas nacionales SABER 11, carece de vivienda propia y tiene madre con bajo nivel educativo, tiene una probabilidad de desertar en la universidad del 60%, mientras que un estudiante que no trabaja, cuenta con vivienda propia y madre con nivel de formación universitario ve reducida su probabilidad de deserción al 42%. Si bien este casi 20% de diferencia es significativo y constata las grandes dificultades que enfrentan los jóvenes de estratos socioeconómicos bajos para llevar a cabo sus estudios.

Es importante mencionar que pertenecer a un grupo étnico puede incidir. Los estudiantes indígenas tienen mayores probabilidades de rezago que el resto de los estudiantes regulares, en función de dinámicas culturales y económicas que los rodean. [12]

D. Conceptualización de la deserción

Castaño, Gallón, Gómez y Vásquez (2006) [13] proponen que "La deserción es un evento individual de interrupción o desvinculación de la trayectoria académica institucional resultado de uno o varios procesos en el plano personal, institucional o social." (p. 48). Así mismo, El Ministerio de Educación Nacional define la deserción como la situación en la que un estudiante se retira de su formación académica sin haber culminado el programa en el tiempo previsto. [15]

La deserción universitaria representa un fenómeno de alto impacto en la educación superior colombiana. En el periodo comprendido entre 2018 y 2023, diversos factores sociales, económicos, institucionales y personales han determinado un aumento o persistencia en los índices de abandono estudiantil, afectando no solo a los estudiantes, sino también a las instituciones de educación superior (IES) y a las metas del país en materia de acceso y equidad educativa [14]

El estudio de la deserción ha avanzado significativamente gracias a la integración de metodologías cuantitativas y cualitativas y en años recientes, a la aplicación de técnicas de ciencia de datos, minería de datos educativa y analítica predictiva, que permiten no solo identificar los factores asociados, sino anticipar comportamientos de riesgo y diseñar estrategias de prevención basadas en evidencia [15,16]

Los estudios recientes confirman que la deserción universitaria en Colombia no es atribuible a una única causa, sino al entrecruce de múltiples factores. En el plano individual,

el bajo rendimiento académico, la escasa motivación, y las dificultades para adaptarse al entorno universitario son recurrentes [17] Desde lo familiar y social, el nivel socioeconómico sigue siendo una de las variables más críticas. Según Leonardo, Andrea y Abad (n.d.), las regiones con menor desarrollo presentan mayores tasas de abandono, reforzando brechas estructurales. [18]

E. Enfoques metodológicos y herramientas con las que se ha estudiado la deserción universitaria

El análisis de la deserción universitaria en Colombia ha experimentado una evolución metodológica considerable en la última década. Inicialmente, las investigaciones se centraban en enfoques cualitativos, sustentados en encuestas, entrevistas o análisis estadísticos convencionales. Sin embargo, con la incorporación de técnicas avanzadas de ciencia de datos, se han abierto nuevas posibilidades para comprender el fenómeno desde una perspectiva más precisa, predictiva y adaptativa.

Entre las herramientas más utilizadas en los estudios revisados se encuentran los algoritmos de clasificación supervisada, como los árboles de decisión, regresión logística y máquinas de soporte vectorial (SVM). Estas técnicas permiten identificar patrones asociados al riesgo de abandono estudiantil a partir de conjuntos de datos complejos. Su uso se ha extendido en universidades como la UNAD, que ha desarrollado modelos predictivos basados en el comportamiento en entornos virtuales de aprendizaje [19, 20]

También es frecuente el uso de redes neuronales artificiales, especialmente en estudios más recientes que requieren modelar relaciones no lineales entre múltiples variables. Esta técnica ha sido particularmente útil para predecir comportamientos de deserción en función de variables como rendimiento académico, uso de plataformas digitales, condiciones socioeconómicas y nivel de interacción institucional [16]. En cuanto a las plataformas tecnológicas utilizadas, destacan lenguajes de programación como Python y R, que permiten un análisis más profundo y personalizado de los datos. Estas herramientas se complementan con softwares de visualización como Power BI y Tableau, utilizados en tableros institucionales para el monitoreo en tiempo real de indicadores clave [21]. Esta combinación de herramientas ha permitido a las universidades generar alertas tempranas e intervenir de forma más oportuna y eficiente.

En resumen, los estudios analizados muestran una creciente madurez metodológica en el tratamiento del problema de la deserción. La ciencia de datos ha permitido pasar de un enfoque explicativo a uno preventivo, en el que las decisiones institucionales pueden anticiparse al comportamiento de los estudiantes. La consolidación de estas prácticas abre el camino hacia un modelo educativo más personalizado, proactivo y centrado en el bienestar estudiantil.

F. Aplicar técnicas de ciencia de datos

Aplicar Técnicas de Ciencia de Datos Para analizar los factores clave de la deserción estudiantil, identificando patrones, tendencias y correlaciones significativas en la información recopilada. La aplicación de técnicas de ciencia de datos ha permitido transformar el estudio de la deserción

estudiantil de una aproximación meramente descriptiva a una interpretación basada en evidencias, donde los patrones, correlaciones y tendencias emergen a partir del análisis sistemático de grandes volúmenes de información [20].

Uno de los modelos más implementados ha sido la regresión logística, que permite calcular la probabilidad de que un estudiante deserte con base en variables independientes como el número de créditos aprobados, el promedio académico acumulado, el historial de cancelaciones, el estrato socioeconómico y el acceso a servicios de bienestar [16]. Este tipo de análisis es útil porque no solo identifica las variables más influyentes, sino que facilita una lectura probabilística del riesgo. [20]

Otro enfoque ampliamente utilizado es el de los árboles de decisión, que estructuran jerárquicamente los factores asociados a la deserción. Este método ofrece una visualización intuitiva y operativa para la gestión institucional, pues permite establecer umbrales concretos sobre los cuales intervenir. Por ejemplo, se ha observado que estudiantes con promedios por debajo de 3.0, que no participan en actividades extracurriculares o que no solicitan apoyos institucionales, presentan mayor propensión a abandonar sus estudios [21].

Los sistemas de alerta temprana también se han convertido en una aplicación práctica del análisis de datos. Estos sistemas utilizan algoritmos que monitorean continuamente indicadores clave y emiten alertas cuando un estudiante presenta signos de riesgo. Así, se pueden activar rutas de intervención como tutorías académicas, asesoría psicológica o apoyos económicos [20].

Por tanto, la aplicación de técnicas de ciencia de datos no solo ha revelado los factores que inciden en la deserción, sino que ha potenciado la capacidad de las instituciones para actuar de forma estratégica y preventiva. Las tendencias identificadas no son únicamente cifras, sino señales que permiten construir rutas más equitativas hacia la permanencia estudiantil [20].

G. Modelos de Machine Learning aplicados a la deserción universitaria

La deserción estudiantil es un fenómeno complejo influenciado principalmente por factores académicos y sociales. En los últimos años, los modelos de Machine Learning (ML) se han posicionado como herramientas poderosas para la predicción temprana de este fenómeno, gracias a su capacidad para modelar relaciones no lineales y extraer patrones en grandes volúmenes de datos. [25, 26, 27]

Algunos de los más mencionados para este caso de estudio en la literatura son: Árboles de decisión, Random Forest, Support Vector Machines (SVM), LightGBM (Light Gradient Boosting Machine), entre otros. Para el desarrollo de este estudio, se seleccionaron tres enfoques representativos de distintas familias algorítmicas: XGBoost, Random Forest y Red Neuronal MLP (Multi-Layer Perceptron), los cuales se describen a continuación.

El modelo XGBoost es uno de los más utilizados y relevantes para abordar la deserción estudiantil. Este algoritmo pertenece a la familia del boosting y se basa en la combinación

secuencial de múltiples árboles de decisión, optimizando una función objetivo regularizada (ver Figura 1) para reducir el sobreajuste y mejorar la capacidad predictiva [25, 26, 29].

$$\mathcal{L}^{(t)} = \sum_{i=1}^n l(y_i, \hat{y}_i^{(t-1)} + f_t(x_i)) + \Omega(f_t), \quad (5)$$

$$\Omega(f) = \gamma T + \frac{1}{2} \lambda \sum_{j=1}^T w_j^2 \quad (6)$$

Figura 1. Función objetivo del XGBoost [25]

Donde f_t representa el nuevo árbol añadido en la iteración t . Su funcionamiento se fundamenta en agregar iterativamente nuevos modelos que corrigen los errores de los anteriores, ajustando los pesos de las observaciones mal clasificadas (ver Figura 2). Este enfoque ha sido ampliamente validado en entornos educativos por su alta precisión y eficiencia computacional [25, 29].




Figura 2. Funcionamiento del XGBoost [25].

Por su parte, el modelo Random Forest representa una evolución del enfoque basado en árboles de decisión. Este método utiliza un conjunto de árboles independientes entrenados sobre diferentes subconjuntos de datos y variables, combinando sus resultados mediante votación o promedio para obtener una predicción final más robusta [27, 31] (ver Figura 3). Su fortaleza radica en la reducción de la varianza y el sobreajuste, además de ofrecer interpretabilidad mediante la estimación de la importancia de las variables predictoras. En el contexto educativo, este algoritmo ha demostrado un desempeño consistente al identificar patrones de deserción asociados con el rendimiento académico y factores demográficos [27, 31].




Figura 3. Esquema general del modelo Random Forest [27].

Finalmente, el modelo de red neuronal multicapa (MLP, Multi-Layer Perceptron) se basa en una arquitectura de neuronas artificiales organizadas en capas interconectadas (entrada, ocultas y salida) como se aprecia en la Figura 4. Cada conexión posee un peso ajustable que se optimiza mediante el algoritmo de backpropagation, minimizando el error entre las predicciones y los valores reales [28, 32]. Las redes neuronales destacan por su capacidad para modelar relaciones complejas y no lineales, aunque requieren normalización de los datos y una calibración cuidadosa de hiperparámetros para evitar el sobreajuste. En estudios recientes, los modelos MLP han mostrado un desempeño competitivo para predecir la deserción universitaria, especialmente cuando se dispone de datos académicos y socioeconómicos representativos [28, 32].




Figura 4. Arquitectura general de una red neuronal multicapa (MLP) compuesta por capas de entrada, ocultas y salida. Fuente: Adaptado de [32].

III. PREGUNTA DE INVESTIGACIÓN Y OBJETIVOS

A. Pregunta de investigación

¿Cuáles son los factores más determinantes de la deserción universitaria en EAFIT y qué modelos predictivos podemos usar para identificar a tiempo estudiantes en riesgo de desertar?

B. Metodología

Se propone un enfoque de análisis predictivo basado en técnicas de minería de datos educativos, integrando variables socioeconómicas, rendimiento académico temprano, y características institucionales.

C. Objetivos

1) Objetivo general

Desarrollar un modelo de Machine Learning para identificar estudiantes en riesgo de deserción universitaria en la Universidad EAFIT en Medellín, Colombia, basado en factores principalmente académicos, pero también algunos socioeconómicos como variables predictoras principales.

2) Objetivos específicos

- Realizar un análisis exploratorio de datos (EDA) para describir el comportamiento de las variables del conjunto de datos, analizando los factores socioeconómicos y académicos asociados con la deserción universitaria en el contexto de la Universidad EAFIT de Medellín.
- Desarrollar y evaluar modelos predictivos de deserción estudiantil, empleando modelos de Machine Learning.

IV. DATOS Y ANÁLISIS PRELIMINAR

La base de datos contiene 2.194.612 millones de registros y 36 columnas. Esta tabla contiene información de notas por materia de los estudiantes de pregrado de la Universidad EAFIT de forma anonimizada, relacionando por semestre académico desde el 2000 hasta el 2025.

Las columnas relacionadas en el *dataset* son las siguientes:

- EMPLID_ANONIMO: identificador anónimo del estudiante.
- NIVEL_ACADÉMICO: Puede contener “Doctorado”, “Maestría”, “Especialización” o “Pregrado”. Para este caso solo contiene “Pregrado”.
- SEMESTRE: Hace referencia al semestre académico en el cual está matriculado cada estudiante.
- ID_MATERIA: Identificador único por materia.
- NRO_MATERIA: Identificador único por materia.
- COD_PROGRAMA: Identificador único por programa académico cursado en la Universidad.
- NOMBRE_PROGRAMA: Nombre del programa académico cursado en la Universidad.
- ESCUELA: Unidad organizativa que agrupa los diversos programas académicos afines dentro de un área del saber. En EAFIT son 5 escuelas: Administración; Derecho; Finanzas, Economía y Gobierno; Artes y Humanidades; Ciencias Aplicadas e Ingeniería.

- NIVEL_ACADÉMICO_CURSO: Nivel académico al que corresponde la materia cursada.
- SISTEMA_CALIFICACIÓN: Tiene 2 alternativas: “C30” que corresponde a las materias que se califican de 0 a 5 y que son aprobadas a partir de 3.0. “C35” corresponde a las materias que son aprobadas a partir de 3.5.
- NOTA: Calificación asociada al estudiante por materia cursada de acuerdo con su desempeño académico. La escala es de 0 a 5, y puede incluir decimales.
- CRÉDITOS: Valor académico que se le otorga a cada materia de acuerdo con su contenido e importancia en el plan académico cursado.
- DISCAPACIDAD: Característica que corresponde al reporte de discapacidades realizado asociado por estudiante. Esta información es reportada por ellos mismos. Las opciones podrían ser: Aprendizaje, auditiva, médica, movilidad, visión, otra.
- FIRST_GENERATION: Corresponde a la caracterización de cada estudiante haciendo referencia a si es el primero de su núcleo familiar (padre, madre, hermanos) que estudia un pregrado.
- DESPLAZADO_VICTIMA_CONFLICTO: Hace referencia a si el estudiante reportó en el formulario de inscripción si fue desplazado de su lugar de residencia debido al conflicto armado. Esta información debe ser oficial (es decir, que el gobierno del país correspondiente tiene registros oficiales de dicho desplazamiento forzado).
- COHORTE: Primer semestre o ingreso a la universidad por estudiante por programa académico.
- DESERTOR: Caracterización si el estudiante desertó del programa académico que venía cursando.
- GRADUADO: Caracterización si el estudiante ya cumplió con todos los requisitos para culminar sus estudios en el programa académico cursado y está graduado.
- ACTIVO: Caracterización si el estudiante continúa estudiando el programa académico; no se ha graduado y no es desertor.
- ESTRATO: Clasificación de la ubicación del lugar de residencia que se realiza a nivel local (en cada ciudad), de acuerdo con las características físicas de la vivienda y sobre todo, el entorno urbanístico o rural que la rodea.

V. ANÁLISIS EXPLORATORIO DE DATOS (EDA)

Un análisis exploratorio de datos, EDA, por sus siglas en inglés Exploratory Data Analysis, es una metodología

estadística que tiene como objetivo principal explorar los datos sin partir de hipótesis predeterminadas o suposiciones previas.

El EDA es una fase crítica en el proceso de análisis de datos que permite explorar y comprender mejor la estructura y las características de los datos. Introducido por John Tukey, el EDA combina técnicas estadísticas y visuales para identificar patrones, detectar anomalías, probar hipótesis preliminares y resumir las principales características de los datos sin realizar suposiciones previas. [22]

A continuación, se presenta el análisis exploratorio de datos organizado en distintas secciones. En primer lugar, el resumen ejecutivo ofrece una descripción general del dataset, sus variables y su alcance. Luego, se realiza el análisis de valores faltantes y las estadísticas descriptivas, que permiten evaluar la calidad y distribución de los datos. Posteriormente, se profundiza en el análisis de las calificaciones (nota) y en el comportamiento temporal. Más adelante, se examinan las diferencias entre escuelas y programas académicos, junto con las características demográficas de los estudiantes. Finalmente, se abordan los patrones de deserción y graduación, así como el análisis de créditos académicos, con el fin de ofrecer una visión integral del comportamiento y desempeño estudiantil.

A. Resumen ejecutivo

Tenemos un dataset con un tamaño de 2.194.612 registros, y 36 columnas o campos. El cual contiene como primeros indicadores clave:

- Estudiantes únicos: 58.406
- Materias únicas: 7.679
- Programas académicos: 32
- Escuelas: 5
- Rango temporal por semestres: 2000-1 a 2025-1

Sobre el rendimiento académico:

- Nota promedio general: 3.86
- Mediana de notas: 4.00
- Desviación estándar: 0.82
- Tasa de aprobación de las materias: 92.57%.

Para la tasa de aprobación se debe tener en cuenta que las materias se aprueban según el sistema de calificación que las identifique, sea que haya materias que se ganen con una nota mayor o igual 3.0, y otras materias que se ganen con una nota mayor o igual a 3.5.

Cabe resaltar, que debido a que el *dataset* solo corresponde al nivel de pregrado, la mayoría de materias se aprueban desde 3.0; no obstante, hay estudiantes quienes en el pregrado ven algunas materias de posgrados, y esas en su mayoría se aprueban desde 3.5.

Sobre datos por Escuela, tenemos:

- Escuela con mejor rendimiento académico: Escuela de Artes y Humanidades con nota promedio 4.15
- Escuela con mayores cifras de matrícula: Escuela de Administración con 933.521 registros.

Indicadores de permanencia estudiantil:

- Tasa de deserción: 32.97%
- Tasa de graduación: 51.56%
- Estudiantes activos: 14,97%

B. Análisis de valores faltantes

La identificación y cuantificación de valores faltantes constituye un paso fundamental en la evaluación de la calidad del conjunto de datos, dado que la presencia de información incompleta puede afectar la validez y confiabilidad de los análisis posteriores. La Tabla 1 presenta el número y porcentaje de valores faltantes por variable, lo que permite dimensionar el grado de completitud del dataset. Asimismo, en la Figura 5 se muestra un histograma que ilustra la distribución de los datos ausentes, facilitando la detección de patrones o concentraciones de ausencia en variables específicas.

Tabla 1. Valores faltantes por columna

Columna	Valores faltantes	Porcentaje
TIPO_SEMESTRE	2.194.612	100,0%
DESC_MOTIVO_ACCIÓN_INSCRIPCIÓN	2.177.011	99,2%
ULT_MOTIVO_ACCION_INSCRIPCION	2.176.626	99,2%
DISCAPACIDAD	2.164.256	98,6%
FIRST GENERATION EPIK	1.963.072	89,5%
DESPLAZADO_VICTIMA_CONFLICTO	1.689.990	77,0%
FIRST GENERATION AYRE	1.099.770	50,1%
FIRST GENERATION	934.503	42,6%
ESTRATO	630.186	28,7%
ULT_ACCION_INSCRIPCION	42.477	1,9%
DESERTOR	327	0,0%
GRADUADO	327	0,0%
ACTIVO	327	0,0%




Figura 5. Gráfica de valores faltantes por columna

En resumen, se identificaron 13 columnas con valores faltantes, de las cuales se eliminaron 6 variables: TIPO_SEMESTRE, DESC_MOTIVO_ACCION_INSCRIPCION, ULT_MOTIVO_ACCION_INSCRIPCION, FIRST_GENERATION_EPIK, FIRST_GENERATION_AYRE, ULT_ACCION_INSCRIPCION por no aportar información relevante ni representativa para los objetivos del estudio.

Posteriormente, se realizaron ajustes en los tipos de datos con el fin de garantizar la coherencia estadística y facilitar los análisis exploratorios posteriores. Para las columnas que conservaron valores faltantes, se aplicaron las siguientes estrategias de imputación:

- **FIRST_GENERATION y DESPLAZADO_VICTIMA_CONFLICTO:** se asumió que los registros sin datos correspondían a estudiantes que no cumplían con dichas condiciones socioeconómicas. Por tanto, los valores ausentes se completaron con 0 y luego se transformaron a tipo booleano (1 = sí cumple, 0 = no cumple).
- **DISCAPACIDAD:** los valores faltantes se reemplazaron por la categoría “Sin discapacidad”. Posteriormente, se generó la variable derivada **TIENE_DISCAPACIDAD**, de tipo booleano, para diferenciar entre estudiantes con (1) y sin reporte de discapacidad (0).
- **ESTRATO:** se completó de forma aleatoria con valores del 1 al 6, respetando la proporción observada en los registros existentes, a fin de conservar la representatividad de la distribución original.

C. Estadísticas descriptivas

El dataset incluye tres variables numéricas principales: Nota, Créditos y Estrato, las cuales constituyen los indicadores cuantitativos fundamentales para los análisis posteriores. En la Tabla 2 se presentan las estadísticas descriptivas correspondientes, las cuales permiten obtener una visión general de la distribución y variabilidad de los datos.

Tabla 2. Estadísticas descriptivas de variables cuantitativas

	NOTA	CRÉDITOS	ESTRATO
Promedio	3,857949	3,326536	4,380989
Desviación estándar	0,815514	2,139776	1,382426
Mínimo	0	1	1
25%	3,4	3	3
50%	4	3	5
75%	4	3	6
Máximo	5	24	6

En relación con las variables categóricas, se observan las siguientes características:

- **SEMESTRE:** presenta 52 valores únicos, correspondientes a los periodos académicos registrados. Los semestres con mayor número de observaciones se muestran en la Tabla 3.

Tabla 3. Semestres con más registros

SEMESTRE	Registros
2018-1	52.555
2019-1	52.346
2017-1	52.042

2016-1	51.352
2020-1	50.599
2018-2	50.192
2017-2	49.995
2025-1	49.989
2016-2	48.824
2019-2	48.488

- **NRO_MATERIA:** cuenta con 7.700 valores únicos, que representan los distintos códigos de asignaturas. Los códigos con mayor frecuencia se detallan en la Tabla 4.

Tabla 4. Códigos de materias con más registros

NRO_MATERIA	Registros
DE0084	23.776
OG0591	23.078
PR0312	14.403
HL0591	13.667
CO0133	13.612
CO0135	13.562
EC0101	12.888
FI0116	12.213
GP0039	11.346
DE0119	11.223

- **NOMBRE_MATERIA:** posee 3.591 valores únicos, correspondientes a los nombres de las asignaturas ofrecidas. Las materias con más registros se presentan en la Tabla 5.

Tabla 5. Nombres de materias con más registros

NOMBRE_MATERIA	Registros
CONSTITUCIÓN Y SOCIEDAD (NFI)	23.776
INICIAT. Y CULT. EMPRL. (NFI)	23.079
FUNDAMENTOS DE CONTABILIDAD	22.468
MATEMÁTICAS FINANCIERAS	20.285
ÁLGEBRA LINEAL	19.630
CÁLCULO DIFERENCIAL	17.059
MATEMÁTICAS 1	15.570
ANÁLISIS TEXTUAL (NFI)	15.502
ECONOMÍA INTERNACIONAL	15.473
ECOLOGÍA	14.538

- **NOMBRE_PROGRAMA:** posee 32 valores únicos, correspondientes a los nombres de los programas académicos que ofrece la universidad. En la Tabla 6 se presentan los programas con más registros.

Tabla 6. Nombres de materias con más registros

Programa	Registros
----------	-----------

Administración de Negocios	546.457
Negocios Internacionales	264.676
Ingeniería Diseño de Producto	156.502
Ingeniería de Sistemas	133.712
Derecho	131.455
Ingeniería Mecánica	129.170
Ingeniería Civil	128.058
Ingeniería de Producción	117.577
Comunicación Social	90.867
Mercadeo	79.284

- **ESCUELA:** incluye 5 valores únicos, que reflejan las diferentes escuelas académicas de la institución. La distribución de registros por escuela se muestra en la Tabla 7.

Tabla 7. Distribución de registros por Escuela

ESCUELA	Registros
Administración	933.521
Ciencias Aplic e Ingeniería	811.385
Artes y Humanidades	190.951
Derecho	131.455
Finanzas, Economía, Gobierno	127.300

- **NIVEL_ACADÉMICO_CURSO:** presenta 4 valores únicos, asociados al nivel académico de los cursos. La distribución respectiva se observa en la Tabla 8.

Tabla 8. Distribución de registros por nivel académico del curso

NIVEL_ACADÉMICO_CURSO	Registros
PREG	2.194.520
MSTR	46
DOCT	43
ESPE	3

- **SISTEMA_CALIFICACIÓN:** presenta dos valores únicos, C30 y C35, con 2.194.529 y 83 registros respectivamente. La distribución muestra una clara predominancia del sistema C30, utilizado en la gran mayoría de los casos, como se detalla en la Tabla 9.

Tabla 9. Distribución de registros por sistema de calificación

SISTEMA_CALIFICACIÓN	Registros
C30	2.194.529
C35	83

- **DISCAPACIDAD:** contiene 6 valores únicos, los cuales corresponden a los distintos tipos de discapacidad reportados. La Tabla 10 presenta la distribución de registros por tipo.

Tabla 10. Distribución de registros por tipo de discapacidad

DISCAPACIDAD	Registros
Visión	24.750
Auditiva	2.816
Movilidad	1.557
Médica	512
Aprendizaje	469
Otra	252

- **COHORTE:** cuenta con 87 valores únicos, representando los diferentes grupos de ingreso de los estudiantes. Las cohortes con mayor número de registros se resumen en la Tabla 11.

Tabla 11. Cohortes con más registros


COHORTE	Registros
2016-1	78.797
2015-1	70.130
2017-1	68.428
2014-1	63.642
2018-1	61.499
2001-1	59.861
2002-1	59.552
2003-1	58.636
2012-1	58.627
2011-1	58.498

D. Análisis de calificaciones


Con el fin de comprender el desempeño académico de los estudiantes, se realizó un análisis detallado de la variable NOTA, la cual representa la calificación obtenida por cada estudiante en las materias cursadas entre los semestres 2000 y 2025.

El análisis estadístico muestra que las calificaciones presentan una media de 3.86, una mediana de 4.00 y una desviación estándar de 0.82, con valores mínimos y máximos de 0.0 y 5.0, respectivamente. Esto sugiere una distribución sesgada hacia calificaciones altas, lo cual es indicativo de un rendimiento académico general positivo entre los estudiantes de pregrado.


La Figura 6 muestra el histograma de distribución de notas, donde se observa que la mayoría de las calificaciones se concentran entre 3 y 5, con un pico alrededor de la nota 4.0. Este comportamiento refleja que una gran proporción de estudiantes mantiene un rendimiento por encima del umbral de aprobación.


Figura 6. Distribución y características estadísticas de las calificaciones obtenidas por los estudiantes de pregrado.

La Figura 7, correspondiente al boxplot, evidencia una dispersión moderada y algunos valores atípicos en el rango inferior (notas menores a 2.0), que podrían corresponder a casos aislados de bajo rendimiento o materias reprobadas.


Figura 7. Boxplot de la distribución de calificaciones de los estudiantes de pregrado.

En cuanto al sistema de calificación, se analizaron los esquemas C30 (aprobado desde 3.0) y C35 (aprobado desde 3.5). La Figura 8 muestra que el promedio de notas fue ligeramente superior en el sistema C30 frente al C35, diferencia que podría explicarse por los distintos criterios de exigencia entre ambos esquemas.


Figura 8. Promedio de calificaciones según el sistema de calificación utilizado (C30 y C35).

Para facilitar la interpretación, las calificaciones se agruparon en cinco categorías: *Muy Bajo* (0–2.5), *Bajo* (2.5–3.0), *Medio* (3.0–3.5), *Bueno* (3.5–4.0) y *Excelente* (4.0–5.0).

La distribución resultante (Figura 9) muestra que la mayor proporción de registros se concentra en las categorías “Bueno” y “Excelente”, lo cual respalda la tendencia general hacia calificaciones altas observada en el análisis descriptivo.




Figura 9. Distribución de estudiantes según la categoría de calificación obtenida.

Finalmente, se estimó la tasa general de aprobación, considerando los criterios definidos por el sistema de calificación de cada materia. El resultado indica que más del 80% de las materias fueron aprobadas, mientras que cerca del 20% fueron reprobadas.

Estos resultados evidencian que, aunque el rendimiento académico promedio de los estudiantes es alto, existe un grupo minoritario con desempeños bajos que podrían estar en riesgo de deserción. Por tanto, la variable NOTA se consolida como uno de los principales indicadores para identificar estudiantes en riesgo de abandonar sus estudios.

E. Análisis temporal

El análisis temporal permite observar la evolución de las calificaciones, la participación estudiantil y la oferta académica a lo largo del tiempo, considerando la información disponible desde el semestre 2000-1 hasta 2025-2, para un total de 52 semestres académicos.

1) Evolución de las notas promedio

La Figura 10 muestra la evolución del promedio y la mediana de las notas por semestre. Se observa una tendencia general estable en el periodo 2000–2019, con valores promedio alrededor de 3.7 a 3.9. Sin embargo, a partir de 2020-1 se identifica un incremento significativo, alcanzando promedios superiores a 4.1 durante los semestres 2020-1 a 2021-1. Este aumento podría estar relacionado con la transición hacia modalidades remotas de enseñanza durante la pandemia, que pudieron afectar los criterios de evaluación o la dinámica académica.

En los años recientes, entre 2022 y 2024, los promedios se mantienen estables alrededor de 4.0, con una leve mejora hacia 2025-1 (4.10) y un valor atípico en 2025-2 (4.58), asociado a registros parciales o incompletos.




Figura 10. Evolución del promedio y la mediana de las notas por semestre.

2) Evolución del número de estudiantes

En la Figura 11 se presenta la cantidad de estudiantes únicos matriculados por semestre, con un crecimiento sostenido entre los años 2000 y 2018, pasando de aproximadamente 6.600 a 10.800 estudiantes. Este aumento refleja una expansión en la población estudiantil universitaria durante ese periodo.



Figura 11. Estudiantes únicos matriculados por semestre.

A partir de 2019, se observa una ligera disminución progresiva, estabilizándose alrededor de 9.000 estudiantes en los semestres posteriores a 2021. El descenso más pronunciado se registra en 2025-2 (167 estudiantes), lo cual indica un semestre aún en desarrollo o con datos incompletos.

3) Oferta académica por semestre

La Figura 12 presenta la cantidad de materias únicas ofrecidas por semestre. En los primeros años del periodo analizado (2000–2007) se observa un crecimiento sostenido, pasando de cerca de 750 a más de 1.300 asignaturas. Posteriormente, entre 2010 y 2015, el número de materias se estabiliza alrededor de 1.000 a 1.100, para luego retomar un crecimiento gradual desde 2016.




Figura 12. Materias únicas ofrecidas por semestre.

El valor máximo se registra en el semestre 2025-1 con 1.488 materias, evidenciando una ampliación en la oferta académica, mientras que el semestre 2025-2 presenta un valor atípicamente bajo (30 materias) asociado nuevamente a datos parciales para ese semestre.

4) Número total de registros por semestre

La Figura 13 muestra el número total de registros académicos por semestre, indicador que combina el volumen de estudiantes, materias y calificaciones. Entre los años 2000 y 2019, se evidencia un crecimiento sostenido desde aproximadamente 35.000 hasta más de 52.000 registros por semestre.




Figura 13. Total de registros académicos por semestre.

El pico máximo se alcanza en 2018-1 (52.555 registros), seguido de una leve reducción durante la pandemia (2020–2021) y una posterior recuperación a niveles superiores a 47.000 registros en 2024-2 y 2025-1. El semestre 2025-2 presenta nuevamente un valor atípico (202 registros), correspondiente a información aún no consolidada.

5) Estadísticas generales del análisis temporal

En conjunto, el análisis temporal evidencia un crecimiento sostenido en la participación estudiantil y la oferta académica hasta finales de la década de 2010, con una estabilización posterior.

- El promedio de estudiantes únicos por semestre fue de 8.524.
- El promedio de materias únicas ofrecidas alcanzó 1.146
- El promedio de registros por semestre fue de 42.204.

El semestre con mayor cantidad de estudiantes fue 2018-1, con 10.894 estudiantes únicos, mientras que el semestre con mayor oferta académica fue 2025-1, con 1.488 materias diferentes.

En síntesis, el análisis temporal revela un comportamiento estable en el rendimiento académico de los estudiantes de pregrado de la Universidad EAFIT entre los años 2000 y 2025, con un promedio general cercano a 3.8. Si bien se observan fluctuaciones leves en periodos específicos, como el incremento de las calificaciones durante la pandemia (2020–2021), la tendencia general apunta hacia la consistencia en los niveles de exigencia y desempeño. Asimismo, la expansión sostenida del número de registros académicos refleja el crecimiento institucional y la diversificación de la oferta educativa. Estos resultados permiten contextualizar los patrones de deserción en el tiempo, sugiriendo que los cambios coyunturales o estructurales en el entorno educativo pueden influir en el comportamiento académico y, potencialmente, en la permanencia estudiantil.

F. Análisis por escuelas y programas académicos

El análisis por escuelas y programas académicos permite identificar diferencias en el rendimiento estudiantil y la distribución de la población entre las distintas áreas del conocimiento en la Universidad EAFIT. Este enfoque ayuda a comprender si existen patrones institucionales que podrían relacionarse con la deserción, considerando tanto la cantidad de estudiantes como su desempeño promedio.

1) Disitribución por escuelas

El conjunto de datos evidencia una concentración significativa de estudiantes en las escuelas de *Administración* (26.579 estudiantes únicos) y *Ciencias Aplicadas e Ingeniería* (21.826), que en conjunto representan más del 70% del total. En contraste, las escuelas de *Derecho* (3.633), *Finanzas, Economía y Gobierno* (4.512) y *Artes y Humanidades* (5.110) agrupan una menor proporción de estudiantes, lo cual refleja una distribución heterogénea en la matrícula según el área del conocimiento. Este comportamiento se aprecia en la Figura 14, donde la *Escuela de Administración* ocupa la mayor proporción en la distribución total.




Figura 14. Distribución de estudiantes únicos por escuela.

En términos de rendimiento académico, las diferencias entre escuelas son notorias. La Figura 15 muestra que la *Escuela de Artes y Humanidades* presenta la nota promedio más alta (4.15) y la mediana más elevada (4.3), seguida por *Finanzas, Economía y Gobierno* (3.90) y *Derecho* (3.88). Las escuelas con menor promedio son *Administración* y *Ciencias Aplicadas e Ingeniería*, ambas con un valor medio de 3.82. Este resultado sugiere que las áreas relacionadas con las humanidades tienden a registrar un desempeño más alto, mientras que los programas técnicos o de negocios presentan una mayor dispersión y exigencia en la evaluación.




Figura 15. Nota promedio por escuela.

2) Análisis por programas académicos

Al profundizar en el nivel de programas, se identifican diferencias aún más marcadas. Los programas con mejor desempeño promedio son Literatura y Música (ambos con una media de 4.34), seguidos por Diseño Interactivo (4.21), Nivelatorio de Música (4.16) y Psicología (4.13). En general, estos pertenecen a la Escuela de Artes y Humanidades, reforzando la tendencia observada a nivel de escuela.

La Figura 16 evidencia también que los programas con mayor cantidad de estudiantes se concentran principalmente en áreas de Administración, Ingeniería y Comunicación Social, lo que demuestra una relación entre el tamaño de la cohorte y la dispersión del rendimiento.




Figura 16. Top 10 programas con mayor número de estudiantes únicos.

En contraste, los programas con menor nota promedio corresponden principalmente a áreas de Ingeniería y Administración, destacándose *Geología y Administración de Negocios* (3.73), seguidos por *Ingeniería Civil*, *Ingeniería Mecánica* y *Economía*, con promedios entre 3.74 y 3.83. La Figura 17 complementa este hallazgo mostrando una mayor variabilidad en las calificaciones dentro de las escuelas con orientación técnica o cuantitativa, frente a una distribución más concentrada en las humanidades.




Figura 17. Top 10 programas con mayor número de estudiantes únicos

G. Análisis de características sociodemográficas

El análisis de las variables sociodemográficas permite comprender mejor el contexto del estudiantado y su relación con el desempeño académico, medido a través de la nota promedio. A continuación, se presentan los principales hallazgos obtenidos a partir del dataset utilizado.

1) Distribución por estrato socioeconómico

La población estudiantil se concentra mayoritariamente en los estratos 5 (19,12%) y 6 (18,75%), seguidos de los estratos 4 (13,18%) y 3 (13,09%), mientras que los estratos 1 y 2 representan solo un 7,15% del total (Figura 18).




Figura 18. Distribución de estudiantes por estrato socioeconómico.

En cuanto al desempeño académico, se observa que los estudiantes de los estratos 2 y 3 obtienen los promedios más altos (3,93 y 3,92, respectivamente), seguidos por los de estrato 6 (3,90) y 5 (3,88). Los resultados muestran que no hay una relación lineal evidente entre estrato y nota promedio, aunque los niveles más bajos no presentan desventajas significativas en el rendimiento (Figura 19).




Figura 19. Nota promedio por estrato socioeconómico.

2) Condición First Generation

El 60,42% de los registros corresponde a estudiantes First Generation, es decir, los primeros en su familia en acceder a la educación superior. Estos estudiantes presentan una nota promedio ligeramente inferior (3,80) frente a quienes no pertenecen a esta categoría (3,95) (ver Figura 20).




Figura 20. Nota promedio por First Generation.

Esta diferencia, aunque pequeña, podría reflejar brechas asociadas a factores de apoyo familiar, capital cultural o acceso a recursos educativos.

3) Condición de discapacidad

Respecto a la condición de discapacidad, el análisis evidencia que el 1,13% de los estudiantes presenta una discapacidad visual, seguida por la auditiva (0,13%) y la de movilidad (0,07%), mientras que otras categorías como médica, de aprendizaje u “otra” presentan porcentajes inferiores al 0,05% del total, como se aprecia en la Tabla 12.

Tabla 12. Distribución de registros por tipo de discapacidad

DISCAPACIDAD	Registros	Porcentaje	Nota
Visión	24.750	1.13%	3.85
Auditiva	2.816	0.13%	3.84
Movilidad	1.557	0.07%	3.97

Médica	512	0.02%	3.85
Aprendizaje	469	0.02%	3.62
Otra	252	0.01%	4.31

Según los resultados presentados en la Tabla 12, los promedios de nota varían entre 3,62 (para estudiantes con discapacidad de aprendizaje) y 4,31 (en la categoría “otra”). Estos valores reflejan una ligera dispersión en el desempeño académico dependiendo del tipo de discapacidad, aunque sin representar diferencias estructurales relevantes en la población general.

4) Condición de desplazamiento por conflicto

Un aspecto relevante es que el 77,34% de los estudiantes son víctimas del conflicto armado o desplazados, mientras que el 22,66% no presenta esta condición. En términos de rendimiento, los primeros registran una nota promedio de 3,83, frente a 3,95 en el grupo no desplazado.

Esta diferencia, aunque no extrema, es consistente y podría indicar la persistencia de condiciones de vulnerabilidad que impactan el desempeño académico, como se observa en la Tabla 13.

Tabla 13. Nota promedio según condición de desplazamiento por conflicto.

DESPLAZADO	Registros	Porcentaje	Nota
Sí	1.697.406	77.34%	3.83
No	497.206	22.66%	3.95

H. Análisis deserción y graduación

El análisis de deserción, graduación y estado activo permite comprender los patrones de permanencia y culminación en la población estudiantil, así como su relación con el rendimiento académico promedio y la evolución temporal de las cohortes.

1) Distribución general por estados académicos

En total, se identificaron 58.406 estudiantes únicos, de los cuales el 52,06 % corresponde a graduados, el 33,46 % a desertores y el 15,47 % a estudiantes activos. Esta distribución, presentada en la Figura 21, evidencia una tendencia favorable hacia la culminación de los estudios, aunque con una proporción considerable de deserción que continúa representando un reto institucional.




Figura 21. Distribución porcentual de estudiantes por estado académico.

En la Figura 22 se observa la nota promedio por estado académico, donde los graduados y estudiantes activos presentan valores muy similares (3,96 y 3,99, respectivamente), mientras que los desertores registran un promedio inferior (3,14). Este resultado sugiere una correlación positiva entre el rendimiento académico y la permanencia: los estudiantes con mejores promedios tienden a culminar su programa o a mantenerse activos, mientras que los de menor desempeño presentan mayor propensión a desertar.




Figura 22. Promedio general de notas según estado académico.

2) Evolución por cohorte

La evolución temporal del comportamiento académico, representada en la Figura 23, permite observar la distribución de estudiantes por cohorte y estado. En las cohortes más antiguas (anteriores al año 2000), se aprecia una mayor proporción de graduados, con tasas de graduación cercanas al 90%. Sin embargo, entre las cohortes del 2000 al 2010 se evidencia un incremento gradual en la deserción, alcanzando valores superiores al 40% en algunos periodos.




Figura 23. Distribución de estudiantes por cohorte y por estado.

A partir de 2021, se observa un aumento importante de estudiantes activos, lo que responde al carácter reciente de estas cohortes, que aún no han completado su proceso académico. Finalmente, la Figura 24 muestra la tasa de deserción por escuela, donde se evidencian diferencias significativas entre unidades académicas, superando algunas de ellas el promedio general (33,46%). Estas variaciones podrían estar vinculadas con factores específicos de cada programa, como su nivel de exigencia, duración o contexto socioeconómico del estudiantado.




Figura 24. Tasa de deserción por escuela.

I. Análisis de créditos académicos

El análisis de créditos académicos permite comprender la estructura de los cursos, su peso dentro de los programas y su relación con el rendimiento y la permanencia estudiantil. A partir de los registros de más de 2,19 millones de materias, se examinan la distribución de créditos, las notas promedio, las tasas de aprobación y su vínculo con el estado académico de los estudiantes.

1) Distribución de créditos por materia

La Figura 25 presenta la distribución de créditos asignados a las materias. Se observa una alta concentración en las asignaturas de 3 créditos, que representan el 63,3% del total, seguidas por las de 4 créditos (18,9%) y 2 créditos (8,6%). Este patrón indica una estructura curricular estandarizada en torno a materias de 3 y 4 créditos, que constituyen más del 80% de la oferta académica.




Figura 25. Distribución de créditos por materia.

El total de créditos registrados asciende a 7,3 millones, con un promedio de 3,33 créditos por materia. Las asignaturas de más de 10 créditos son poco frecuentes y corresponden principalmente a espacios curriculares especiales o prácticas de grado, lo que explica su baja frecuencia (menos del 1% en conjunto).

2) Relación entre créditos y rendimiento académico

En la Figura 26 se muestra la relación entre el número de créditos y la nota promedio obtenida. Se aprecia que las materias de 1 a 2 créditos presentan los promedios más altos (4,35 y 4,05 respectivamente), mientras que las de 3 y 4 créditos —las más comunes— tienden a tener notas promedio más bajas (3,82 y 3,68).




Figura 26. Nota promedio según número de créditos.

Este comportamiento sugiere que las asignaturas de menor carga crediticia podrían corresponder a cursos optativos, talleres o módulos complementarios, donde los estudiantes alcanzan mejores calificaciones, en contraste con los espacios más exigentes de 3 o 4 créditos.

La Figura 27, que representa la distribución de notas por número de créditos mediante boxplots, confirma esta tendencia: se observa una mayor dispersión en las notas de materias de 3 y 4 créditos, con presencia de valores cercanos al límite de aprobación (3,0), lo que refleja mayor variabilidad y complejidad académica en estas asignaturas.




Figura 27. Distribución de notas por créditos.

3) Tasa de aprobación según número de créditos

La Figura 28 muestra la tasa de aprobación promedio por número de créditos. Se observa una alta tasa general de aprobación (superior al 90%) en la mayoría de los casos. Las materias de 1 a 2 créditos alcanzan tasas de 95% y 94%, y en cambio las de 3 y 4 créditos presentan valores ligeramente inferiores (92% y 91% respectivamente).




Figura 28. Tasa de aprobación por número de créditos.

En contraste, algunas materias de alta carga (18 y 20 créditos) muestran niveles de aprobación cercanos al 100%, posiblemente asociadas a prácticas, pasantías o trabajos finales en los que los estudiantes suelen estar en etapas avanzadas de su formación.

Los valores atípicos observados en materias de 16 y 24 créditos, con 0% de aprobación, se deben al bajo número de registros (menos de 10 casos), por lo que no representan un patrón significativo.

4) Créditos acumulados y estado académico

La Figura 29 presenta el promedio de créditos acumulados según el estado del estudiante. Los resultados muestran diferencias marcadas:

- Graduados: 180,2 créditos en promedio
- Activos: 83,6 créditos
- Desertores: 54,6 créditos

Estos datos reflejan que los graduados completan, en promedio, más del triple de créditos que los desertores, lo que resulta consistente con el avance esperado dentro de los programas académicos. Los valores intermedios en los estudiantes activos evidencian que aún se encuentran en proceso de completar su plan de estudios.




Figura 29. Créditos promedio por estado del estudiante.

5) Relación entre créditos acumulados y nota promedio

En la Figura 30 se analiza la relación entre los créditos acumulados y la nota promedio por estudiante. Se observa una correlación positiva moderada: los estudiantes con mayor número de créditos tienden a tener mejores promedios y, en general, menores tasas de deserción.

Los puntos de color verde, correspondientes a estudiantes exitosos (no desertores), se concentran en rangos altos tanto de créditos como de notas, mientras que los puntos rojos (desertores) se agrupan en valores bajos de ambas variables. Este patrón evidencia que la acumulación progresiva de créditos es un indicador asociado al éxito académico y a la permanencia estudiantil.

En general se observa que los cursos de 3 y 4 créditos concentran más del 80% de los registros, con notas promedio de 3,82 y 3,68, y tasas de aprobación de 92% y 91% respectivamente.




Figura 30. Créditos acumulados vs. nota promedio.

Las materias de alta carga (18 y 20 créditos) presentan tanto notas como tasas de aprobación superiores al 4,6 y 99%,

mientras que las de baja carga muestran también altos rendimientos. En conjunto, estos resultados sugieren que la estructura curricular mantiene una consistencia entre la carga crediticia y el nivel de exigencia académica, con un rendimiento más alto en los extremos (cursos cortos y finales de carrera).

J. Correlaciones y relaciones

1) Correlaciones entre variables numéricas

La Figura 31 presenta la matriz de correlación entre las principales variables numéricas analizadas, incluyendo el promedio de notas, los créditos totales cursados, el número de materias registradas y los estados académicos (desertor, graduado y activo).




Figura 31. Matriz de correlación de variables numéricas.

Se observa una fuerte relación positiva entre el número de materias y los créditos totales ($r = 0.96$), lo cual es esperable, ya que ambas variables reflejan la carga académica acumulada del estudiante. También se identifica una correlación negativa importante entre la condición de desertor y variables asociadas al rendimiento o progreso académico, como los créditos totales ($r = -0.62$), el número de materias ($r = -0.62$) y el promedio de notas ($r = -0.53$). Esto indica que los estudiantes con menor rendimiento o avance académico tienden a desertar con mayor frecuencia.

Asimismo, se evidencia una correlación positiva moderada entre el promedio de notas y la condición de graduado ($r = 0.36$), lo que sugiere que los estudiantes con mejores desempeños académicos alcanzan mayores tasas de graduación. La relación inversa entre las variables “desertor” y “graduado” ($r = -0.72$) confirma la coherencia interna del modelo de datos.

En general, las correlaciones numéricas muestran un patrón consistente entre desempeño, avance y permanencia

académica, evidenciando que las variables de rendimiento son predictores relevantes del éxito o abandono en los programas.

2) Relaciones entre variables categóricas y el rendimiento académico

Los resultados del análisis de varianza (ANOVA), resumidos en la Tabla 14, indican que todas las variables categóricas analizadas presentan diferencias estadísticamente significativas en las calificaciones promedio ($p < 0.05$). Las variables con mayor impacto sobre la nota fueron *First Generation* ($F = 18,276.54$), *Escuela* ($F = 7,422.40$), *Desplazado/Víctima de Conflicto* ($F = 7,402.69$) y *Estrato Socioeconómico* ($F = 262.90$).

Tabla 14. Resultados de análisis ANOVA

VARIABLE	F-statistic	p-value	Sig.
FIRST_GENERATION	18276,54	0.000000e+00	Sí
ESCUELA	7422,40	0.000000e+00	Sí
DESPLAZADO_VICTIMA_CONFLICTO	7402,69	0.000000e+00	Sí
ESTRATO	262,90	6,07E-282	Sí

Estos resultados muestran que el rendimiento académico no es homogéneo entre los distintos grupos, sino que está influenciado por factores tanto socioeconómicos como institucionales. En particular, la condición de *first generation* (primer miembro de la familia en acceder a educación superior) y el contexto de vulnerabilidad por desplazamiento o conflicto presentan los contrastes más marcados en las notas promedio.

3) Factores demográficos y socioeconómicos asociados a la deserción

Las tasas de deserción confirman la influencia de los factores demográficos y socioeconómicos sobre la permanencia estudiantil.

Por estrato, se observa en la Figura 32 que los estudiantes del estrato 1 presentan la tasa de deserción más alta (33.7%), mientras que los de estratos 5 y 6 muestran las más bajas (23.5%). Esto sugiere una relación inversa entre el nivel socioeconómico y el riesgo de abandono.




Figura 32. Tasa de deserción por estrato.

La variable *First Generation* (ver Figura 33) refleja también una brecha relevante: los estudiantes que son los primeros en su familia en cursar estudios universitarios presentan una tasa de deserción de 38.9%, en contraste con 24.6% para quienes no lo son.




Figura 33. Tasa de deserción por First Generation.

Respecto a la condición de discapacidad, las tasas más elevadas se registran (ver Figura 34) en estudiantes con discapacidad visual (36.6%) y auditiva (35.8%), lo que evidencia desafíos de inclusión y acompañamiento académico en estos grupos.




Figura 34. Tasa de deserción por tipo de discapacidad.

Finalmente, los estudiantes que reportan haber sido desplazados o víctimas del conflicto armado presentan una tasa de deserción del 38.5%, más del doble que quienes no tienen esa condición (17.9%), como se muestra en la Figura 35.




Figura 35. Tasa de deserción en estudiantes desplazados víctimas del conflicto.

Estos resultados reafirman que la deserción universitaria está fuertemente asociada a condiciones socioeconómicas y contextuales, además del desempeño académico, evidenciando la necesidad de políticas de apoyo diferenciadas para poblaciones vulnerables.

K. Conclusiones del análisis exploratorio de datos

El análisis exploratorio de datos permitió comprender en profundidad el comportamiento académico de los estudiantes, así como identificar patrones relevantes asociados a la deserción. Los resultados mostraron que la mayoría de los estudiantes alcanzan un rendimiento académico satisfactorio, con una nota promedio general cercana a 3,86, aunque existe un grupo significativo con bajo desempeño que coincide con los registros de deserción. En particular, los estudiantes desertores presentan un promedio de 3,14, notablemente inferior al de los graduados (3,96) y activos (3,99), lo que confirma que el rendimiento académico es un factor crítico asociado al abandono.

El análisis temporal evidenció una tendencia de incremento en la tasa de deserción en cohortes más recientes, mientras que la distribución por escuelas y programas reveló diferencias significativas en las tasas promedio de notas y en la proporción de desertores. Estos hallazgos sugieren que la deserción no responde a un único factor, sino a una combinación de variables académicas, institucionales y posiblemente sociodemográficas.

A partir de estos resultados, se identifican varias variables candidatas para la construcción del modelo predictivo, entre ellas:

- Promedio académico y tendencia de notas a lo largo de los períodos.
- Escuela y programa académico, dado su impacto diferencial en el rendimiento y permanencia.
- Estado actual del estudiante (activo, graduado, desertor) como variable objetivo.
- Número de materias inscritas y aprobadas, cuando esté disponible, como indicador de carga y progreso académico.
- Condición de discapacidad que, aunque minoritaria, podría aportar información relevante sobre barreras de permanencia.

La información obtenida en esta etapa servirá de base en las siguientes secciones para el diseño de varios modelos de Machine Learning, cuyo objetivo será predecir la probabilidad de deserción de un estudiante a partir de sus características académicas e institucionales.

VI. MÉTODOS

A. Selección y depuración del conjunto de datos

Con base en los análisis expuestos en el análisis exploratorio de datos, se decidió enfocar el análisis predictivo de la variable DESERCIÓN para la Escuela de Ciencias Aplicadas e Ingeniería de la Universidad EAFIT dado que es la

segunda escuela más importante junto con la Escuela de Administración representando el 79% de los registros del dataset original. Adicional, es la escuela con mayor cantidad de pregrados ofrecidos (14), y teniendo en cuenta que este es nuestro foco, contiene la mayor cantidad de pregrados para analizar.

Tras aplicar este primer filtro, el conjunto de datos quedó conformado por 811.385 registros y 24 variables. Posteriormente, se excluyeron los programas Biología, Geología y Diseño Urbano y Gestión del Hábitat, dado que sus planes de estudio no corresponden a la naturaleza ingenieril del análisis planteado. Con esta depuración, se obtuvo un dataset de 766.994 registros y 24 columnas, correspondientes a nueve programas de ingeniería.

Con el propósito de identificar variables académicas relevantes para la predicción temprana de la deserción, se seleccionaron las asignaturas comunes a todos los programas de ingeniería, bajo los siguientes criterios:

- Pertenecer a los primeros semestres del plan de estudios, con el fin de anticipar la deserción temprana.
- Formar parte del ciclo común de formación de ingeniería.
- Ser materias obligatorias en todos los programas.
- Excluir asignaturas electivas o de formación no específica en ingeniería.

Como resultado, se eligieron las siguientes materias: Cálculo 1 (o Cálculo Diferencial), Cálculo 2 (o Cálculo Integral), Álgebra Lineal, Ecuaciones Diferenciales, Estadística y Física 1. Tras filtrar el dataset en función de estas asignaturas, se obtuvieron 70.570 registros y 24 columnas.

Para garantizar registros únicos por estudiante y programa, se realizó una agrupación por las variables EMPLID_ANÓNIMO, COD_PROGRAMA, NOMBRE_PROGRAMA, DESERTOR, GRADUADO, ACTIVO, FIRST_GENERATION, DESPLAZADO_VICTIMA_CONFLICTO, ESTRATO, MATERIA_CORTA, TIENE_DISCAPACIDAD y COHORTE, empleando como función de agregación el promedio de la NOTA. De este proceso resultó un dataset con 49.812 registros y 13 columnas, representando un registro único por estudiante, programa y cohorte.

Posteriormente, se pivotaron las seis materias seleccionadas, de manera que cada columna representara una asignatura y su nota respectiva. Este procedimiento produjo un dataset final de 16.943 registros y 17 columnas, apto para su uso en modelos de aprendizaje automático.

B. Tratamiento de valores faltantes

Durante el preprocesamiento, se identificó una cantidad significativa de valores faltantes en las notas de algunas materias, especialmente en cohortes previas al año 2010. Este hallazgo confirmó la hipótesis de que los planes de estudio

antiguos presentaban variaciones en nombres y estructuras curriculares, lo que dificultaba su correspondencia con las materias seleccionadas.

Por tal motivo, se restringió el análisis a las cohortes comprendidas entre 2010 y 2018, garantizando así la homogeneidad curricular de las observaciones incluidas. La Tabla 15 presenta el número de valores faltantes identificados por materia.

Tabla 15. Datos faltantes por materia

Materia	# Datos faltantes
Cálculo 1	1.391
Cálculo 2	16.703
Ecuaciones	7.582
Física 1	9.319
Álgebra lineal	6.873

Debido a su alta proporción de valores faltantes, la asignatura Cálculo 2 fue descartada del análisis. Para las demás materias, los valores ausentes se imputaron con cero (0), bajo el supuesto de que correspondían a estudiantes que cursaron la materia pero no la aprobaron, y cuyos registros no aparecían en el dataset original. Esta decisión permitió mantener la coherencia de los promedios académicos, evitando la sobreestimación del rendimiento de los estudiantes desertores.

La Figura 36 muestra la cantidad promedio de materias cursadas por los desertores entre las cohortes de 2010 y 2018, evidenciando la relación entre el número de asignaturas aprobadas y la propensión a la deserción.

Finalmente, se estableció como límite superior la cohorte 2018, dado que, según los registros institucionales, el tiempo promedio de finalización de los programas de pregrado en la Universidad EAFIT es de aproximadamente seis años (doce semestres). En consecuencia, las cohortes posteriores no presentan trayectorias académicas completas, lo que impide determinar con certeza si los estudiantes han cursado todas las asignaturas seleccionadas.




Figura 36. Cantidad de materias vistas por los desertores en las cohortes del 2010 al 2018.

C. Normalización de variables

Para garantizar la comparabilidad de las variables y optimizar el desempeño de los modelos de aprendizaje automático, se aplicó un proceso de normalización a todas las

variables numéricas incluidas en el análisis. Las variables normalizadas fueron las siguientes:

- PROMEDIO_MATERIAS
- Las notas de CALCULO1
- Las notas de ECUACIONES
- Las notas de ESTADISTICA
- Las notas de FISICA1
- Las notas de ALGEBRA_LINEAL
- ESTRATO

El método de normalización empleado fue Min-Max Scaling, el cual ajusta los valores al rango [0, 1] de acuerdo con la ecuación:

$$x' = \frac{x - x_{\min}}{x_{\max} - x_{\min}}$$

Esta técnica mejora la estabilidad y la convergencia de los modelos, al asegurar que todas las variables contribuyan de manera equilibrada al proceso de entrenamiento. Además, permite evitar que variables con escalas numéricas más amplias dominen el aprendizaje, lo que resulta especialmente importante en modelos basados en gradiente como XGBoost o redes neuronales. [33]–[35].

Durante esta etapa, también se incorporó la variable TIENE_DISCAPACIDAD, la cual ya había sido mencionada en la sección de Análisis Exploratorio de Datos (EDA) y cuya creación se justificó durante el análisis de valores faltantes. En dicha etapa, se determinó que la variable original DISCAPACIDAD debía transformarse para facilitar su interpretación y uso dentro del modelo. Por tanto, se optó por convertirla en una variable booleana que asigna el valor 1 a los estudiantes que reportaron alguna discapacidad y 0 a aquellos que no lo hicieron, simplificando así su tratamiento sin requerir la creación de variables dummy adicionales.

Por su parte, las variables FIRST_GENERATION y DESPLAZADO_VICTIMA_CONFLICTO ya se encontraban codificadas como booleanas desde el EDA, por lo cual no fue necesario aplicarles ningún proceso de normalización adicional.

En conjunto, estas transformaciones permitieron obtener un conjunto de datos homogéneo y coherente, listo para la fase de modelado predictivo mediante los algoritmos de Machine Learning seleccionados.

D. Matriz de correlación con el dataset filtrado y normalizado

La matriz de correlación se construyó considerando exclusivamente las cohortes comprendidas entre 2010 y 2018. Como se explicó previamente en la sección de selección de cohortes, este rango garantiza la disponibilidad de trayectorias académicas completas, dado que el tiempo promedio de graduación en los programas de pregrado de la Universidad EAFIT es de aproximadamente seis años (doce semestres). Las cohortes anteriores a 2010 fueron descartadas debido a

inconsistencias curriculares y denominaciones de asignaturas, mientras que las posteriores a 2018 aún no completan su recorrido académico.

El análisis de correlación incluyó tanto las variables socioeconómicas ESTRATO_NORMALIZADO, FIRST_GENERATION, DESPLAZADO_VICTIMA_CONFLICTO y TIENE_DISCAPACIDAD como las variables académicas normalizadas correspondientes a las cinco materias seleccionadas: Cálculo 1, Ecuaciones Diferenciales, Estadística, Física 1 y Álgebra Lineal.

Los resultados presentados en la Figura 37 muestran que las variables socioeconómicas no presentan correlaciones significativas con la variable DESERCIÓN, lo que sugiere que su influencia en el abandono estudiantil es marginal dentro del contexto analizado. En cambio, las variables académicas evidencian una correlación negativa moderada a fuerte con la deserción, lo que indica que un menor desempeño en estas materias está asociado a una mayor probabilidad de abandonar los estudios.

En particular, se destaca la influencia de las asignaturas de Ecuaciones Diferenciales ($r = -0.62$) y Estadística ($r = -0.54$), que muestran los coeficientes de correlación más altos en magnitud. Cálculo 1 ($r = -0.44$) y Álgebra Lineal ($r = -0.41$) presentan una relación similar, mientras que Física 1 exhibe una correlación más débil ($r = -0.28$). Estos resultados respaldan la hipótesis de que el rendimiento académico temprano en las asignaturas básicas de Ingeniería constituye un indicador determinante para la predicción de la deserción estudiantil.




Figura 37. Matriz de correlación entre variables normalizadas.

E. Conclusiones del preprocesamiento previo a los modelos de Machine Learning

El proceso de depuración y transformación de los datos permitió consolidar un conjunto de información confiable,

coherente y adecuado para la aplicación de los modelos predictivos de Machine Learning. Las decisiones tomadas en las etapas anteriores —filtrado de cohortes, tratamiento de valores faltantes, selección de variables y normalización— garantizan que el dataset final refleje de manera fiel las condiciones académicas y socioeconómicas relevantes para el análisis de deserción estudiantil.

El dataset preprocesado resultante presenta las siguientes características principales:

- **Tamaño final:** 9 468 registros y 28 columnas.
- **Estructura:** un registro único por estudiante, por programa académico y por cohorte.
- **Cobertura temporal:** cohortes comprendidas entre los años 2010 y 2024, lo que asegura la inclusión de trayectorias académicas completas hasta la cohorte 2018 y registros recientes para predicción.
- **Homogeneidad:** todas las variables numéricas y categóricas fueron normalizadas o convertidas a tipo booleano, lo que optimiza su compatibilidad con los algoritmos de aprendizaje automático.
- **Pertinencia predictiva:** las variables con mayor capacidad explicativa frente a la deserción son aquellas relacionadas con el rendimiento académico temprano, particularmente las notas en las materias de Ecuaciones Diferenciales, Estadística, Física 1, Cálculo 1 y Álgebra Lineal, lo que coincide con los patrones observados en la matriz de correlación.

En conjunto, este preprocesamiento proporciona una base sólida para el entrenamiento, validación y comparación de los modelos predictivos seleccionados (XGBoost, Random Forest y Redes Neuronales MLP), asegurando que los resultados obtenidos se fundamenten en información estructurada, consistente y representativa del fenómeno de deserción universitaria en los programas de ingeniería de la Universidad EAFIT.

VII. RESULTADOS POR MODELO PREDICTIVO

El desarrollo de modelos predictivos constituye la etapa central de este estudio, orientada a estimar la probabilidad de deserción estudiantil a partir del desempeño académico temprano y de variables socioeconómicas relevantes. Una vez completado el proceso de preprocesamiento y normalización de los datos, se implementaron tres algoritmos de Machine Learning supervisado ampliamente reconocidos por su eficacia en tareas de clasificación binaria: XGBoost, Random Forest y Perceptrón Multicapa (MLP).

Estos modelos se seleccionaron por su capacidad para capturar relaciones no lineales entre las variables y su eficacia demostrada en estudios previos de predicción de deserción universitaria. Cada modelo se entrenó inicialmente con sus parámetros por defecto y, posteriormente, se realizaron tres iteraciones de ajuste de hiperparámetros con el fin de optimizar su rendimiento y analizar la sensibilidad ante los cambios de configuración.

En esta sección se describen los parámetros de entrenamiento empleados, el procedimiento de validación adoptado y las métricas utilizadas para evaluar el rendimiento de los modelos en la iteración inicial.

A. Configuración de los conjuntos de datos y variables

Para todos los modelos, se emplearon como variables de entrada las cinco asociadas al rendimiento académico temprano:

- CALCULO1_NORMALIZADO,
- ECUACIONES_NORMALIZADO,
- ESTADISTICA_NORMALIZADO,
- FISICA1_NORMALIZADO y
- ALGEBRA_LINEAL_NORMALIZADO.

La variable objetivo fue **DESERTOR**, la cual indica si el estudiante continuó o abandonó sus estudios.

El conjunto de datos se dividió en dos partes según la disponibilidad de trayectorias completas:

- **Entrenamiento (2010–2018):** cohortes con información académica completa.
- **Prueba (2019+):** cohortes recientes, empleadas para evaluar la capacidad de generalización de los modelos.

B. Modelo XGBoost

El modelo XGBoost se entrenó con 5.927 registros, empleando los parámetros:

- objective='binary:logistic',
- eval_metric='logloss',
- random_state=42,
- learning_rate=0.1,
- n_estimators=150,
- max_depth=4

El modelo no requirió imputación de valores faltantes, dado que el preprocesamiento de datos ya había sido completado previamente. Los resultados muestran un rendimiento robusto, con métricas elevadas en todas las categorías:

- Accuracy: 0.919 (porcentaje total de predicciones correctas)
- Precision: 0.924 (de los estudiantes clasificados como desertores, cuántos realmente lo son)
- Recall: 0.826 (Sensibilidad de los desertores reales, cuántos fueron identificados por el modelo)
- F1: 0.872 (equilibrio entre precisión y recall (ideal cuando hay clases desbalanceadas))
- ROC-AUC: 0.97 (mide la capacidad de distinguir entre desertores y no desertores (0.5 = aleatorio, 1.0 = perfecto). Si el AUC está entre 0.70–0.85, el modelo

tiene buena capacidad discriminante con solo cinco variables académicas, lo que es un resultado sólido)

Durante esta fase, el modelo mostró un desempeño robusto y estable como se presenta en la Tabla 16.

Tabla 16. Resultados detallados del modelo XGBoost (entrenamiento 2010–2018)

Clase	Precision	Recall	F1-Score	Support
False (No desertor)	0.92	0.97	0.94	3.950
True (Desertor)	0.92	0.83	0.87	1.977
Overall Accuracy			0.92	5.927
Macro avg	0.92	0.90	0.91	5.927
Weighted avg	0.92	0.92	0.92	5.927

Las Figuras 38 y 39 presentan las matrices de confusión y curvas ROC para el conjunto de entrenamiento, respectivamente. Los resultados reflejan una adecuada discriminación entre desertores y no desertores, con un bajo número de falsos negativos.




Figura 38. Matriz de confusión de los datos de entrenamiento (2010–2018) para el modelo XG Boost.




Figura 39. Curva ROC de los datos de entrenamiento (2010–2018) para el modelo XG Boost.

El modelo XGBoost fue evaluado con 2.316 registros correspondientes a cohortes desde 2019, con el fin de validar su capacidad de generalización sobre datos recientes. Arrojó estos resultados:

- Accuracy: 0.881 (porcentaje total de predicciones correctas)
- Precision: 0.825 (de los estudiantes clasificados como desertores, cuántos realmente lo son.)
- Recall: 0.799 (Sensibilidad de los desertores reales, cuántos fueron identificados por el modelo)
- F1: 0.812 (equilibrio entre precisión y recall (ideal cuando hay clases desbalanceadas)
- ROC-AUC: 0.911 (mide la capacidad de distinguir entre desertores y no desertores (0.5 = aleatorio, 1.0 = perfecto). Si el AUC está entre 0.70–0.85, el modelo tiene buena capacidad discriminante con solo cinco variables académicas, lo que es un resultado sólido.)

Como se observa en la Tabla 17, el modelo mantiene un desempeño sólido, con una exactitud global del 88 %, confirmando la estabilidad del aprendizaje obtenido en la etapa de entrenamiento.

Tabla 17. Resultados detallados del modelo XGBoost (2019+)

Clase	Precision	Recall	F1-Score	Support
False (No desertor)	0.91	0.92	0.91	1573
True (Desertor)	0.82	0.80	0.81	743
Overall Accuracy			0.88	2316
Macro avg	0.87	0.86	0.86	2316
Weighted avg	0.88	0.88	0.88	2316

En términos generales en la fase de prueba se confirma la robustez del modelo, mostrando una ligera disminución en las métricas esperada por la generalización.

Según los resultados obtenidos:

- El modelo alcanza un buen equilibrio entre precisión y recall, indicando que identifica correctamente una proporción considerable de desertores sin clasificar excesivamente a quienes no desertan.
- El AUC de 0.77 en las cohortes 2019+ confirma que el modelo distingue bien entre desertores y no desertores, incluso con solo cinco variables académicas.
- La leve caída de las métricas en la cohorte de prueba es normal y sugiere generalización adecuada, sin sobreajuste.

Para interpretar los resultados de la matriz de confusión, se deben comprender las relaciones entre predicciones y valores reales, como se resume en la Tabla 18:

Tabla 18. Interpretación de la matriz de confusión

	Predijo No desertor	Predijo Desertor
Real No desertor	Verdaderos negativos	Falsos positivos

Real Desertor	Falsos negativos	Verdaderos positivos
---------------	------------------	----------------------

- Muchos falsos negativos, significa que el modelo no detecta algunos desertores.
- Muchos falsos positivos, significa que clasifica erróneamente a estudiantes como desertores.

En los resultados de la evaluación del modelo, la matriz de confusión obtenida (Figura 40), da cuenta que:

- La mayoría de los no desertores fueron correctamente clasificados.
- Sin embargo, aún hay algunos falsos negativos, es decir, estudiantes que desertaron, pero el modelo predijo que continuarían.

Esto implica que el modelo tiende a ser conservador (prefiere errar menos prediciendo deserción donde no hay) — un comportamiento útil si se quiere minimizar alarmas falsas, pero podría requerir ajuste de umbral (por ejemplo, de 0.5 a 0.4) si el interés institucional es detectar más casos en riesgo.




Figura 40. Matriz de confusión con el dataset de prueba (2019+) para el modelo XG Boost.

La Curva ROC, evalúa la calidad de las probabilidades del modelo. Mientras más se aleje la curva de la diagonal y el AUC sea alto, mejor distingue entre desertores y no desertores.

El gráfico ROC (Figura 41) de este modelo, muestra una curva claramente por encima de la diagonal, lo que confirma una buena capacidad de discriminación.




Figura 41. Curva ROC con el dataset de prueba (2019+) para el modelo XG Boost.

El área bajo la curva ($AUC \approx 0.77$) indica que, en promedio, el modelo asigna mayor probabilidad de deserción a los desertores reales que a los no desertores en el 77% de los casos. En modelos educativos con variables exclusivamente académicas, este nivel de desempeño es notablemente alto.

La importancia de las variables elegidas para el modelo (ver Figura 42), permiten concluir lo siguiente:

- Las materias de primer contacto con el pensamiento matemático formal (Cálculo 1, Física 1 y Álgebra) tienen un peso más alto en la predicción.
- Esto sugiere que el rendimiento temprano en matemáticas y razonamiento abstracto es un fuerte predictor de riesgo de deserción.
- Estadística y Ecuaciones tienen menor peso, pero refuerzan el patrón de consistencia en el razonamiento lógico y cuantitativo.
- Este hallazgo coincide con estudios previos que vinculan la deserción en ingeniería con dificultades iniciales en matemáticas fundamentales.
- Las notas normalizadas reflejan que el rendimiento relativo dentro del grupo es más importante que la nota cruda.
- Al centrarse solo en materias de primer año, el modelo evalúa el riesgo académico temprano, útil para alertas tempranas institucionales.



Figura 42. Importancia de las variables o features para el modelo XG Boost.

En el análisis agregado, sobre el conjunto de prueba el sistema predice 357 desertores de un total de 2.316 estudiantes, lo que representa el 15.41%, mientras que 1.959 estudiantes (84.59%) fueron clasificados como no desertores (Figura 43).




Figura 43. Distribución general de predicciones (2019+) para el modelo XG Boost.

La distribución de probabilidades muestra una concentración alta en los extremos, lo que sugiere buena confianza del modelo. (Figura 44).




Figura 44. Distribución de probabilidad de predicción (2019+) para el modelo XG Boost.

Por cohorte, la tasa proyectada de deserción oscila entre 10.6% y 20.7%, con una tendencia leve al aumento en los últimos años (Figura 45).



Figura 45. Proyección de estudiantes como desertores por cohorte para el modelo XG Boost.

A nivel de programa, los de mayor probabilidad media ubica a Ingeniería Mecánica e Ingeniería Agronómica como las de mayor riesgo con una probabilidad media aproximada de 0.32, seguidas por Sistemas, Procesos y Civil (Figura 46).

No obstante, Programas como Ingeniería Física, Ingeniería Matemática y Ingeniería de Diseño de Producto muestran menor probabilidad media de deserción, posiblemente porque son programas que de acuerdo con su perfil tan técnico y matemático, estas primeras materias evaluadas no son tan determinantes para la deserción de ellos y probablemente más adelante en el programa de estudios encuentren materias mucho más complejas que sí influyan en su decisión de seguir estudiando.




Figura 46. Programas con mayor probabilidad media de deserción para el modelo XG Boost.

Finalmente, el mapa de calor cohorte-programa (Figura 47) permite identificar:

- El mapa de calor confirma que los programas con mayor intensidad en matemáticas puras a lo largo de todo el programa presentan tonos más claros, lo que indica riesgo de deserción más bajo.
- En contraste, algunos programas exhiben picos rojos aislados, asociados a cohortes específicas afectadas por el rendimiento académico de las 5 variables de entrada tomadas para el modelo.




Figura 47. Porcentaje de deserción proyectados por cohorte y programa

C. Modelo Random Forest

El modelo Random Forest se entrenó utilizando los parámetros por defecto de la librería `sklearn.ensemble.RandomForestClassifier`, con el fin de evaluar primero el comportamiento base del algoritmo. Posteriormente, se realizaron ajustes en la profundidad máxima

de los árboles (`max_depth`) para analizar el efecto de este parámetro sobre la capacidad predictiva y evitar el sobreajuste.

El modelo no requirió imputación de valores faltantes, ya que el proceso de preprocesamiento había sido completado previamente.

Los resultados de la etapa de entrenamiento evidencian un rendimiento estable y equilibrado entre precisión y sensibilidad, como se observa en las siguientes métricas y en la Tabla 19:

- Accuracy: 0.916
- Precision: 0.900
- Recall: 0.841
- F1: 0.869
- ROC-AUC: 0.957

Tabla 19. Resultados detallados del modelo Random Forest (entrenamiento 2010–2018)

Clase	Precision	Recall	F1-Score	Support
False (No desertor)	0.92	0.95	0.94	3.950
True (Desertor)	0.90	0.84	0.87	1.977
Overall Accuracy			0.92	5.927
Macro avg	0.91	0.90	0.90	5.927
Weighted avg	0.92	0.92	0.91	5.927

Las Figuras 48 y 49 presentan las matrices de confusión y las curvas ROC para los conjuntos de entrenamiento, respectivamente. En esta etapa se observa una clasificación precisa de ambas clases, con una curva ROC que alcanza un área superior al 0.95, confirmando una alta capacidad de separación entre desertores y no desertores.




Figura 48. Matriz de confusión de los datos de entrenamiento (2010–2018) para el modelo Random Forest.




Figura 49. Curva ROC de los datos de entrenamiento (2010-2018) para el modelo Random Forest.

En la fase de prueba, el modelo mantiene un rendimiento competitivo y se presentaron los resultados generales en la Tabla 20:

- Accuracy: 0.875
- Precision: 0.798
- Recall: 0.818
- F1: 0.808
- ROC-AUC: 0.914

Tabla 20. Resultados detallados del modelo Random Forest (2019+)

Clase	Precision	Recall	F1-Score	Support
False (No desertor)	0.91	0.90	0.91	1.573
True (Desertor)	0.80	0.82	0.81	743
Overall Accuracy			0.88	2.316
Macro avg	0.86	0.86	0.86	2.316
Weighted avg	0.88	0.88	0.88	2.316

La matriz de confusión muestra una adecuada proporción entre verdaderos positivos y negativos, manteniendo un balance entre la identificación de desertores y la minimización de falsos positivos (Figura 50).




Figura 50. Matriz de confusión con el dataset de prueba (2019+) para el modelo Random Forest.

Por su parte, la curva ROC (Figura 51) evidencia un área bajo la curva de 0.914, lo cual ratifica un desempeño estable, con buena capacidad de discriminación entre ambas clases.




Figura 51. Curva ROC con el dataset de prueba (2019+) para el modelo Random Forest.

En el análisis agregado, el modelo predice 762 desertores (32.9%) de un total de 2.316 estudiantes, mientras que 1.554 (67.1%) fueron clasificados como no desertores (Figura 52).




Figura 52. Distribución general de predicciones (2019+) para el modelo Random Forest.

La distribución de probabilidades muestra un patrón bimodal con alta separación entre las clases, indicando una confianza considerable del modelo (Figura 53).




Figura 53. Distribución de probabilidad de predicción (2019+) para el modelo Random Forest.

Por cohorte, la tasa proyectada de deserción oscila entre 27.4% y 44.3%, alcanzando su punto máximo en la cohorte 2022-2 (Figura 54).




Figura 54. Proyección de estudiantes como desertores por cohorte para el modelo Random Forest.

A nivel de programa, el top 10 de mayor probabilidad media ubica a *Ingeniería Agronómica* (0.48) e *Ingeniería de Sistemas* (0.47) como las de mayor riesgo, seguidas por *Ingeniería de Procesos y Producción* (Figura 55).




Figura 55. Programas con mayor probabilidad media de deserción para el modelo Random Forest.

El mapa de calor cohorte-programa (Figura 56) permite identificar los periodos y programas con mayor incidencia de deserción proyectada, consolidando la capacidad explicativa del modelo en términos temporales y académicos.




Figura 56. Porcentaje de desertores proyectados por cohorte y programa — modelo Random Forest.

D. Modelo MLP

El modelo de redes neurales Multilayer Perceptron (MLP) se implementó utilizando la clase `MLPClassifier` de la librería `sklearn.neural_network`, configurado con tres capas ocultas de tamaños [64, 32, 16], función de activación *ReLU*, optimizador *adam* y `random_state=42` para asegurar reproducibilidad.

El modelo se entrenó con las mismas variables preprocesadas y normalizadas mediante el método *Min-Max*, aplicando los mismos conjuntos de entrenamiento (2010–2018) y prueba (2019+) utilizados en los modelos anteriores.

Durante la fase de entrenamiento, el modelo presentó un rendimiento competitivo, aunque con una ligera reducción en *recall* para la clase de desertores, como se observa en las siguientes métricas y en la Tabla 21:

- Accuracy: 0.907
- Precision: 0.919
- Recall: 0.790
- F1: 0.850
- ROC-AUC: 0.946

Tabla 21. Resultados detallados del modelo MLP (entrenamiento 2010–2018)

Clase	Precision	Recall	F1-Score	Support
False (No desertor)	0.90	0.97	0.93	3.950
True (Desertor)	0.92	0.79	0.85	1.977
Overall Accuracy			0.91	5.927
Macro avg	0.91	0.88	0.89	5.927
Weighted avg	0.91	0.91	0.91	5.927

Las Figuras 57 y 58 presentan la matriz de confusión y la curva ROC correspondientes al conjunto de entrenamiento. En ambas se aprecia una separación clara entre las clases y un área bajo la curva (AUC) de 0.95, que evidencia una buena capacidad del modelo para distinguir entre estudiantes desertores y no desertores.




Figura 57. Matriz de confusión de los datos de entrenamiento (2010–2018) para el modelo MLP.




Figura 58. Curva ROC de los datos de entrenamiento (2010–2018) para el modelo MLP.

El modelo fue posteriormente evaluado con 2.316 registros pertenecientes a cohortes desde el 2019, con el fin de validar su capacidad de generalización. Los resultados fueron los siguientes y los generales que se muestran en la Tabla 22:

- Accuracy: 0.878
- Precision: 0.825
- Recall: 0.787
- F1: 0.806
- ROC-AUC: 0.911

Tabla 22. Resultados detallados del modelo MLP (2019+)

Clase	Precision	Recall	F1-Score	Support
False (No desertor)	0.90	0.92	0.91	1.573
True (Desertor)	0.82	0.79	0.81	743
Overall Accuracy			0.88	2.316
Macro avg	0.86	0.85	0.86	2.316
Weighted avg	0.88	0.88	0.88	2.316

La Figura 59 muestra la matriz de confusión del conjunto de prueba, donde se observa una adecuada identificación de ambas clases, aunque con un leve incremento de falsos negativos frente a los falsos positivos.



Figura 59. Matriz de confusión con el dataset de prueba (2019+) para el modelo MLP.

La Figura 60, correspondiente a la curva ROC, refleja un área bajo la curva de 0.91, lo que ratifica una alta capacidad discriminativa del modelo sobre datos no vistos.




Figura 60. Curva ROC con el dataset de prueba (2019+) para el modelo MLP.

El análisis agregado del modelo MLP muestra que, de los 2.316 estudiantes evaluados, 709 (30.61%) fueron clasificados como desertores, mientras que 1.607 (69.39%) permanecen como no desertores (Figura 61).




Figura 61. Distribución general de predicciones (2019+) para el modelo MLP.

La distribución de probabilidades presenta una concentración bimodal pronunciada, indicando que el modelo tiende a asignar valores de alta confianza en ambos extremos (Figura 62).

En tanto, por cohorte, la tasa de deserción proyectada varía entre 23.7% y 43.0%, alcanzando su punto máximo en la cohorte 2022-2, lo que sugiere un leve incremento en los últimos periodos (Figura 63).




Figura 62. Distribución de probabilidades de deserción con MLP.




Figura 63. Proyección de estudiantes como desertores por cohorte para el modelo MLP.

A nivel de programa académico, los resultados muestran que *Ingeniería Agronómica* (0.47), *Ingeniería de Sistemas* (0.39) y *Ingeniería de Procesos* (0.38) presentan las mayores probabilidades medias de deserción (Figura 64).




Figura 64. Programas con mayor probabilidad media de deserción para el modelo MLP.

Finalmente, el mapa de calor cohorte–programa (Figura 65) permite visualizar los patrones combinados de riesgo, mostrando una coincidencia con los resultados obtenidos en los modelos XGBoost y Random Forest, lo que refuerza la consistencia del patrón detectado por los distintos enfoques de aprendizaje automático.




Figura 65. Porcentaje de desertores proyectados por cohorte y programa — modelo MLP.

VIII.DISCUSIÓN DE LOS RESULTADOS

A. Interpretación general de los modelos

Los tres modelos implementados —XGBoost, Random Forest y Multilayer Perceptron (MLP)— mostraron un desempeño satisfactorio al predecir la probabilidad de deserción estudiantil a partir de cinco variables académicas clave. En términos generales, todos lograron métricas superiores al 0.85 en *Accuracy* y al 0.90 en *ROC-AUC*, confirmando que el rendimiento temprano en asignaturas básicas de matemáticas y ciencias exactas constituye un predictor confiable del riesgo de abandono.

En el conjunto de entrenamiento (2010–2018), XGBoost obtuvo el mejor equilibrio entre *Precision* y *Recall* (0.924 y 0.826, respectivamente), mientras que Random Forest y MLP mostraron valores ligeramente inferiores, pero con mayor estabilidad frente a la variabilidad de los datos. En la fase de validación (2019+), las tres arquitecturas mantuvieron un rendimiento sólido, con una caída esperada de entre 3 y 5 puntos porcentuales en *F1-score*, lo que evidencia una adecuada generalización y ausencia de sobreajuste.

Los resultados confirman que la deserción puede anticiparse de forma efectiva con variables exclusivamente académicas, lo que refuerza la validez del enfoque propuesto para escenarios institucionales donde los datos socioeconómicos o personales no están disponibles.

A nivel conceptual, los tres algoritmos coinciden en que el rendimiento en asignaturas de base matemática —particularmente Ecuaciones Diferenciales, Estadística y Álgebra Lineal— es el principal predictor de abandono, lo que sugiere que los modelos están capturando patrones estructurales coherentes con la literatura sobre retención en ingeniería.

B. Comparación del desempeño entre modelos

La Tabla 23 resume las métricas principales de los modelos sobre el conjunto de prueba:

Tabla 23. Métricas principales de todos los modelos

Modelo	Accuracy	Precision	Recall	F1	ROC_AUC
--------	----------	-----------	--------	----	---------

XGBoost	0.881	0.825	0.799	0.812	0.911
Random Forest	0.875	0.798	0.818	0.808	0.914
MLP	0.878	0.825	0.787	0.806	0.911

El modelo XGBoost destacó por su capacidad de generalización, alcanzando un ROC-AUC de 0.97 en entrenamiento y 0.911 en prueba. Su equilibrio entre Precision (0.825) y Recall (0.799) indica una clasificación robusta, evitando sesgos hacia falsos positivos o negativos.

En términos de discriminación global (ROC-AUC), Random Forest y XGBoost superan levemente al MLP. Sin embargo, el MLP presenta un mejor equilibrio entre Precision y Accuracy, siendo más conservador al clasificar como desertores solo a los casos con alta probabilidad, lo que lo hace útil en contextos donde se busca minimizar alarmas falsas.

El Random Forest, por su parte, logra el Recall más alto, lo que implica que identifica una mayor proporción de desertores reales, característica deseable si el objetivo institucional es la detección temprana de riesgo.

Por su parte, el MLP presentó métricas comparables. Aunque sus resultados fueron marginalmente inferiores, su desempeño reafirma la consistencia del conjunto de datos y la capacidad del perceptrón multicapa para modelar relaciones no lineales.

En conjunto, los tres modelos muestran resultados coherentes y mutuamente consistentes, lo que refuerza la validez de los patrones hallados.

C. Efecto de la modificación de parámetros

Con el objetivo de optimizar el rendimiento de los algoritmos, se evaluaron distintas configuraciones de hiperparámetros para XGBoost, Random Forest y MLP, considerando métricas de Accuracy, Precision, Recall, F1 y ROC-AUC (Tabla 24).

Tabla 24. Variación de parámetros en la configuración de los modelos

Modelo	Parámetros	Accuracy	Precision	Recall	F1	ROC-AUC
XGBoost	{'learning_rate': 0.05, 'max_depth': 3}	0.879965	0.815468	0.808883	0.812162	0.912754
XGBoost	{'learning_rate': 0.1, 'max_depth': 4}	0.881261	0.825000	0.799462	0.812030	0.911458
XGBoost	{'learning_rate': 0.2, 'max_depth': 6}	0.870898	0.796791	0.802153	0.799463	0.905220
RandomForest	{'n_estimators': 150, 'max_depth': 10, 'criterion': 'gini'}	0.878670	0.819945	0.796770	0.808191	0.911204
RandomForest	{'n_estimators': 250, 'max_depth': None, 'criterion': 'gini'}	0.873057	0.813986	0.783311	0.798354	0.908924
RandomForest	{'n_estimators': 200, 'max_depth': 15, 'criterion': 'entropy'}	0.872193	0.809986	0.786003	0.797814	0.908722
MLP	{'hidden_layer_sizes': (50, 25), 'activation': 'relu'}	0.877807	0.819444	0.794078	0.806562	0.912494
MLP	{'hidden_layer_sizes': (100, 50), 'activation': 'relu'}	0.877375	0.820979	0.790040	0.805213	0.910156
MLP	{'hidden_layer_sizes': (150, 100, 50), 'activation': 'tanh'}	0.863558	0.777633	0.804845	0.791005	0.894202

La Figura 66 muestra la jerarquía final considerando todas las métricas integradas, mientras que la Figura 67 visualiza la similitud entre las áreas bajo la curva ROC de los tres enfoques. Los resultados mostraron diferencias mínimas entre modelos, con valores muy cercanos al 0.91 en ROC-AUC y promedios ponderados superiores a 0.84 en el ranking final. Esto evidencia que las tres aproximaciones logran una capacidad de discriminación similar para identificar estudiantes con riesgo de deserción.

Modelo	Parámetros	Accuracy	Precision	Recall	F1	ROC-AUC	Puntaje_final
0	XGBoost ('learning_rate': 0.05, 'max_depth': 3)	0.880	0.815	0.809	0.812	0.913	0.849
1	RandomForest ('n_estimators': 150, 'max_depth': 10, 'criterion': 'gini')	0.879	0.820	0.797	0.808	0.911	0.848
2	MLP ('hidden_layer_sizes': (50, 25), 'activation': 'relu')	0.878	0.819	0.794	0.807	0.912	0.848

Figura 66. Ranking final de modelos (mejor configuración por tipo)




Figura 67. Curvas ROC (mejor configuración por tipo)

Como se evidencia, las métricas más equilibradas corresponden a XGBoost, que obtiene el mejor ROC-AUC (0.913) y F1 (0.812), lo que confirma su superioridad en clasificación binaria con datos tabulares. La combinación de *learning_rate* = 0.05 y *max_depth* = 3 ofreció el mejor equilibrio entre precisión y generalización. Aumentar la profundidad de los árboles elevaba el *Recall*, pero incrementaba también el riesgo de sobreajuste.

El Random Forest destacó por su mayor precisión, ya que el mejor desempeño se obtuvo con 150 árboles y *max_depth* = 10, mostrando robustez y estabilidad sin pérdida significativa en ninguna métrica.

En MLP, la estructura de capas (50, 25) y activación *ReLU* alcanzó la convergencia más eficiente, superando configuraciones más profundas que tendían a una ligera sobre-representación de la clase mayoritaria. Logró métricas muy cercanas, reafirmando que con una arquitectura liviana (50–25 neuronas ocultas) puede igualar el rendimiento de los modelos de ensamble.

Estas variaciones evidencian que una mayor complejidad del modelo no siempre implica mejor desempeño, especialmente en escenarios donde las variables son de naturaleza tabular y su número es limitado.

En el caso de estudio, el resultado tiene un significado claro: los tres modelos son fiables para detectar riesgo académico temprano, siendo capaces de anticipar con alta probabilidad qué estudiantes podrían abandonar sus estudios basándose únicamente en el rendimiento de cinco materias iniciales.

El hecho de que las diferencias entre los modelos sean tan pequeñas sugiere que la deserción presenta patrones consistentes y fuertemente determinados por el desempeño académico inicial, más que por la técnica de modelado empleada. Esto valida la hipótesis de que la deserción, en este contexto, puede predecirse de forma precisa con algoritmos ligeros y fácilmente integrables en sistemas de alerta institucional.

En términos prácticos, XGBoost se recomienda como el modelo preferente para la implementación debido a su ligera superioridad global y a su eficiencia computacional en predicciones en tiempo real. Sin embargo, Random Forest y MLP constituyen alternativas igualmente válidas, en especial en escenarios donde se prioriza la interpretabilidad (Random Forest) o la posibilidad de extender el modelo hacia arquitecturas más complejas como MLP.

D. Interpretación de las variables predictoras

En los tres modelos, las materias con mayor peso predictivo fueron Ecuaciones diferenciales, Estadística y Álgebra Lineal. Estos resultados refuerzan la hipótesis de que el rendimiento en asignaturas cuantitativas básicas constituye un indicador temprano del riesgo de deserción, coincidiendo con investigaciones previas en el ámbito de ingeniería (García et al., 2021; López & Pérez, 2023). El patrón común sugiere que las dificultades iniciales en razonamiento lógico-matemático impactan la permanencia, por lo que las estrategias de apoyo académico deberían concentrarse en este eje durante los primeros semestres.

Por otro lado, materias como Física I y Cálculo I, aunque con menor peso relativo, cumplen una función de filtro o diagnóstico inicial. Su contribución al modelo sugiere que las dificultades detectadas en estos cursos pueden anticipar trayectorias de riesgo, incluso si no se traducen inmediatamente en abandono. De este modo, el sistema de predicción puede servir como herramienta de seguimiento longitudinal, complementando los mecanismos institucionales de tutoría académica y acompañamiento estudiantil.

Además, la distribución de las predicciones por cohorte evidencia una tendencia al alza entre 2020 y 2021, periodo coincidente con la pandemia y la transición a la virtualidad, lo que podría haber incrementado los factores de riesgo no académicos.

A nivel de programa, Ingeniería Agronómica, Sistemas y Mecánica concentran las mayores probabilidades de abandono, posiblemente asociadas a las exigencias de las materias analizadas o al perfil de ingreso de los estudiantes.

La consistencia del patrón entre modelos refuerza la solidez del enfoque, indicando que la variable “rendimiento académico temprano” es suficiente para generar predicciones confiables y replicables.

Finalmente, al comparar la relevancia relativa de las variables entre los modelos, se observa que XGBoost y Random Forest tienden a asignar mayor peso a Ecuaciones diferenciales y Estadística, mientras que el MLP equilibra la importancia entre todas las materias. Esta diferencia refleja la naturaleza de cada enfoque: los modelos basados en árboles capturan interacciones jerárquicas más marcadas, mientras que la red neuronal distribuye la influencia de manera más gradual. No obstante, la coherencia general entre los tres confirma la consistencia del patrón de aprendizaje detectado.

E. Limitaciones del estudio y validez de los resultados

1) Limitaciones del enfoque y los datos

El modelo se construyó exclusivamente con variables académicas cuantitativas derivadas de las notas de cinco asignaturas comunes a los programas de ingeniería. Este enfoque, si bien permite captar patrones objetivos y fácilmente disponibles en los sistemas institucionales, no incorpora factores personales, económicos, psicológicos ni contextuales, que en la literatura especializada se reconocen como determinantes adicionales de la deserción.

Asimismo, el análisis se centró en el rendimiento temprano (primeros semestres), lo cual restringe la interpretación a causas iniciales de abandono. No se incluyen trayectorias de mediano o largo plazo que podrían reflejar decisiones influenciadas por aspectos externos al desempeño académico, como cambios de carrera, condiciones laborales o percepción del entorno universitario.

Por otra parte, al no aplicarse imputación de valores faltantes, algunos programas o cohortes con registros incompletos quedaron excluidos del análisis. Esto asegura la integridad de las observaciones utilizadas, pero reduce la representatividad del conjunto total de estudiantes matriculados durante el periodo de estudio.

2) Limitaciones metodológicas

Aunque los tres algoritmos presentan una capacidad de generalización adecuada, la validación se realizó sobre una sola partición temporal (entrenamiento 2010–2018, prueba 2019+). Si bien este enfoque respeta la naturaleza cronológica de los datos, no se implementó validación cruzada temporal o k-fold, que permitiría estimar de forma más robusta la variabilidad de las métricas.

De igual manera, el número limitado de hiperparámetros ajustados restringe el espacio de búsqueda y deja abierta la posibilidad de que configuraciones alternativas pudieran ofrecer mejoras marginales en desempeño, especialmente en el modelo MLP.

Adicionalmente, la ausencia de métricas de costo de error limita el análisis de impacto de los falsos positivos y falsos negativos en términos operativos. En contextos educativos, un falso negativo —un desertor no detectado— puede tener consecuencias más críticas que un falso positivo, por lo que futuras investigaciones deberían incorporar evaluaciones de sensibilidad y ajuste de umbral de decisión.

3) *Validez y generalización de los resultados*

A pesar de las limitaciones mencionadas, la coherencia observada entre los tres modelos refuerza la validez interna del estudio. El alto grado de convergencia en las métricas (ROC-AUC entre 0.911 y 0.913) y la estabilidad de las variables predictoras más relevantes demuestran que los patrones identificados son consistentes y reproducibles dentro del mismo dominio institucional.

Sin embargo, la validez externa —es decir, la posibilidad de aplicar los resultados a otras universidades o contextos educativos— debe asumirse con cautela. Factores como los planes de estudio, metodologías de evaluación o características del estudiantado pueden alterar los patrones de deserción, por lo que se recomienda replicar el modelo con datos de otras instituciones antes de su adopción generalizada.

F. *Aportes y aplicaciones prácticas*

Los resultados de este estudio proporcionan evidencia empírica sobre la efectividad de aplicar técnicas de Machine Learning al análisis de la permanencia estudiantil, especialmente en contextos donde la información disponible proviene principalmente del desempeño académico. El enfoque demuestra que, aun con un conjunto limitado de variables, es posible construir modelos predictivos precisos y generalizables que apoyen la toma de decisiones institucionales.

En el ámbito universitario, los hallazgos respaldan la creación de un sistema de alerta temprana capaz de detectar oportunamente a los estudiantes con mayor riesgo de deserción. Dicho sistema puede integrarse en las plataformas académicas existentes para generar reportes automáticos sobre el nivel de riesgo individual, priorizando la atención en cohortes recientes. En términos operativos, se concibe como un módulo dinámico que actualiza la probabilidad de deserción de cada estudiante según su rendimiento semestral, facilitando intervenciones oportunas en tutorías, acompañamiento y programas de bienestar académico.

Asimismo, la interpretación de las variables más influyentes en los modelos ofrece una base analítica para la revisión de los currículos iniciales en programas de ingeniería, promoviendo una distribución más equilibrada de la carga conceptual y una mayor articulación entre las asignaturas críticas del primer año.

Desde la perspectiva metodológica, la comparación entre algoritmos demuestra que diferentes enfoques —como los modelos de ensamble y las redes neuronales— pueden

converger hacia resultados consistentes cuando se dispone de datos debidamente depurados, equilibrados y representativos.

Más allá de la predicción de la deserción, este trabajo constituye un avance hacia la consolidación de ecosistemas de analítica educativa basados en datos institucionales. En ellos, el aprendizaje automático puede actuar como un soporte continuo para la planificación académica, la evaluación de políticas de permanencia y la gestión preventiva de riesgos estudiantiles. Además, la metodología implementada puede adaptarse para abordar otros fenómenos asociados, como el bajo rendimiento, el rezago o el cambio de programa, consolidando una gestión universitaria más proactiva, personalizada y sustentada en evidencia.

G. *Cierre del capítulo*

En conclusión, los tres modelos analizados exhiben un desempeño sobresaliente en la predicción del riesgo de deserción universitaria, validando la hipótesis de que el rendimiento académico temprano constituye un indicador robusto de abandono.

El modelo XGBoost se destaca como el más equilibrado, con la mayor capacidad de generalización y precisión, seguido por Random Forest y MLP, que confirman la consistencia del patrón detectado.

Este capítulo proporciona una interpretación integral de los resultados y una base sólida para las conclusiones y recomendaciones del estudio, orientadas a fortalecer las estrategias de permanencia estudiantil y el uso de analítica predictiva en la gestión universitaria.

IX. CONCLUSIONES

A. *Síntesis de hallazgos principales*

El estudio permitió comprobar que el rendimiento académico temprano es un predictor confiable del riesgo de deserción universitaria. A partir de cinco asignaturas base del ciclo común de ingeniería, los modelos desarrollados —XGBoost, Random Forest y MLP— lograron métricas de precisión superiores al 87 % y áreas bajo la curva (ROC-AUC) mayores a 0.90, evidenciando una relación clara entre el desempeño inicial y la probabilidad de abandono.

El modelo XGBoost se destacó como el de mejor desempeño global, con un F1-score de 0.812 y ROC-AUC de 0.913, seguido muy de cerca por Random Forest y MLP, cuyas métricas confirman la estabilidad y reproducibilidad de los patrones identificados.

En conjunto, los hallazgos validan que el desempeño en las materias base del ciclo común de ingeniería es un indicador temprano del riesgo de abandono y puede aprovecharse para generar alertas preventivas con precisión cercana al 90 %.

Los resultados confirman que la deserción puede predecirse tempranamente mediante variables objetivas, con utilidad directa para estrategias institucionales de alerta y retención.

B. Conclusiones generales

1) En relación con el análisis exploratorio de datos (EDA)

Se identificaron patrones y tendencias relevantes en las variables académicas, evidenciando diferencias significativas por programa y cohorte. El análisis temporal mostró un leve aumento en la deserción en años recientes (2020–2021), asociado posiblemente al contexto de virtualidad. Este objetivo permitió comprender la estructura del fenómeno antes del modelado.

2) Respecto al desarrollo y evaluación de modelos predictivos

Los tres algoritmos aplicados demostraron alta capacidad de generalización. El XGBoost obtuvo el mejor desempeño global ($F1 = 0.812$; $ROC-AUC = 0.913$), seguido de Random Forest y MLP, cuyos resultados fueron muy cercanos, validando la estabilidad del conjunto de datos y la coherencia de los patrones detectados.

3) Sobre la interpretación de las variables relevantes

Las materias relacionadas con razonamiento matemático — Ecuaciones Diferenciales, Estadística y Álgebra Lineal — mostraron la mayor influencia en las predicciones, lo cual concuerda con teorías sobre la retención en programas de ingeniería y refuerza la validez académica del modelo.

4) En cuanto al cumplimiento del objetivo general

Se logró desarrollar y evaluar tres modelos de Machine Learning capaces de identificar con alta precisión estudiantes en riesgo de deserción, utilizando información académica disponible en los sistemas institucionales, sin requerir variables externas.

En conjunto, estas conclusiones muestran que los objetivos específicos fueron alcanzados, y que el modelo propuesto puede ser implementado como una herramienta práctica para apoyar decisiones institucionales sobre permanencia.

C. Líneas de trabajo futuro

- Ampliación de variables: Incorporar otros factores socioeconómicos, emocionales y de bienestar estudiantil para enriquecer la predicción y comprender la deserción desde una perspectiva integral.
- Validación temporal y externa: Probar los modelos con cohortes posteriores a 2023 y en otras escuelas académicas de la universidad para evaluar su estabilidad y transferibilidad.
- Despliegue aplicado: Integrar los modelos a un sistema de alerta temprana institucional que automatice la detección de riesgo y genere reportes personalizados para directivos y docentes.

- Optimización de modelos: Experimentar con técnicas avanzadas de ensamble o redes neuronales profundas para mejorar el recall sin sacrificar precisión.

REFERENCES

- [1] Munizaga Mellado, F. R., Cifuentes Orellana, M. B., & Gabriele, A. J. B. (2018). Retención y Abandono Estudiantil en la Educación Superior Universitaria en América Latina y el Caribe: Una Revisión Sistemática. *Education Policy Analysis Archives*, 26, 61. <https://doi.org/10.14507/EPAA.26.3348>
- [2] Ramírez Heredia, R. C., & Carcausto-Calla, W. (2024). Factors Associated with Student Dropout in Latin American Universities: Scoping Review. *Journal of Educational and Social Research*, 14(2), 184-195. <https://doi.org/10.36941/jesr-2024-0026>
- [6] Falla, M., & Vargas-Cañas, R. (2019). Factors Contributing to School Dropout at the University of Cauca. *Educação & Realidade*, 44(2), e84142. <https://doi.org/10.1590/2175-6236130607vs02>
- [7] González-Nucamendi, A., et al. (2023). Predictive analytics study to determine undergraduate students at risk of dropout. *Frontiers in Education*, 8, 1244686. <https://doi.org/10.3389/educ.2023.1244686>
- [8] Fernández-Martín, T., et al. (2018). Un análisis multinomial y predictivo de los factores asociados a la deserción universitaria. *Revista Electrónica Educare*, 23(1), 1-22. <https://doi.org/10.15359/REE.23-1.5>
- [10] Durán, D., Pérez-Almonacid, R., Rodríguez, A., Reverón, C. y Pinto, M. (2007). *Cuestión de Supervivencia. Graduación, deserción y rezago en la Universidad Nacional de Colombia*. Bogotá: Universidad Nacional de Colombia. Recuperado de http://www.bienestar.unal.edu.co/wp-content/uploads/2015/05/cuestion_supervivencia.pdf.
- [11] Centro de Estudios Económicos -CEDE-, Universidad de Los Andes. (2007). *Investigación sobre deserción en las instituciones de educación superior en Colombia* [Informe final]. Bogotá: Universidad de los Andes. Recuperado de <http://studylib.es/doc/7619308/informe-%C3%A9cnico-del-cede---ministerio-de-educaci%C3%B3n>.
- [12] Rodríguez-Urrego, Marcela. (2019). La investigación sobre deserción universitaria en Colombia 2006-2016. Tendencias y resultados. *Pedagogía y Saberes*, (51), 49-66. Retrieved September 28, 2025, from http://www.scielo.org.co/scielo.php?script=sci_arttext&pid=S0121-24942019000200049&lng=en&tlng=es.
- [13] Castaño, E., Gallón, S., Gómez, K. y Vásquez, J. (2006). Análisis de los factores asociados a la deserción y graduación estudiantil universitaria. *Lecturas de Economía*, 65, 9-36. Recuperado de http://www.alfaguia.org/alfaguia/files/1319760796_15.pdf
- [14] SPADIES. (2023). Estadísticas de deserción en educación superior. Ministerio de Educación 43 Nacional. https://www.mineducacion.gov.co/sistemasinfo/spadies/secciones/Estadistica_sde-desercion/
- [15] Ministerio de Educación Nacional de Colombia. (s. f.). Metodología de seguimiento, diagnóstico y elementos para su prevención en la educación superior colombiana. Imprenta Nacional de Colombia. <https://www.mineducacion.gov.co>
- [16] Gutiérrez, D. A., Vélez Díaz, J. F., & López, J. M. (2021). Indicadores de deserción universitaria y factores asociados. *EducaT: Educación Virtual, Innovación y Tecnologías*, 2(1), 15–26. <https://doi.org/10.22490/27452115.4738>
- [17] Salcedo Escarria, A. (2020). Deserción universitaria en Colombia. *Academia y Virtualidad*, 3(1), 50–60. <https://revistas.unimilitar.edu.co/index.php/ravi/article/view/5461>
- [18] Leonardo, G. B., Arias, A. J., & Abad, E. P. (s. f.). Deserción universitaria en el contexto 42 colombiano: Recorrido diacrónico entre 2018 y 2022. *Revista Senderos Pedagógicos*, 13, 97–111.
- [19] Universidad de Deusto. (2023, diciembre). Una aproximación al fenómeno de la deserción estudiantil en la Universidad Nacional Abierta y a Distancia: Retos para la construcción de un modelo de permanencia. *Revista de Investigaciones: Universidad de Deusto*. <https://research-ebSCO-com.bibliotecavirtual.unad.edu.co>
- [20] Losada, C.A. (2025). Estrategias basadas en ciencia de datos para la predicción y reducción de la deserción en Instituciones públicas de educación superior en Medellín. <https://repository.unad.edu.co/handle/10596/73574>
- [21] Sapiencia. (s. f.). Deserción en la educación superior. Observatorio de Educación Superior en Medellín (ODES). <https://sapiencia.gov.co>
- [22] Cruz Ruiz, J., Vásquez López, J.A., Ruelas Santoyo, E.A., Esparza Diaz, L.E., (2025). Análisis exploratorio de datos aplicado a una base de datos de los

sismos registrados del año 1970 al año 2022. <https://pistaseducativas.celaya.tecnm.mx/index.php/pistas/article/view/3598>

[23] Castro H., M. P. (2025). *Aprendizaje-de-máquina – Deserción Universitaria* [Repositorio de código]. GitHub. <https://github.com/mpcastroh/Aprendizaje-de-maquina---Desercion-Universitaria/tree/main>

[24] Universidad EAFIT. (s. f.). *EAFIT en cifras*. Recuperado en octubre de 2025, de <https://www.eafit.edu.co/eafit-en-cifras#230548828-628354916>

[25] Fajardo Gil, O. P., Useche Becerra, D. A., & Hernández Novoa, T. M. (2025, junio). *Predicción y análisis de la deserción estudiantil en la Facultad de Ingeniería de la Universidad El Bosque mediante modelos avanzados de Machine Learning: Identificación de variables más influyentes, caracterización de graduados y no graduados, y detección temprana* [Trabajo de grado, Universidad El Bosque]. Repositorio Institucional Universidad El Bosque. <https://repositorio.unbosque.edu.co/items/86c40122-9885-4687-8c7d-24feaf3a4a4c>

[26] T. Chen and C. Guestrin, “XGBoost: A scalable tree boosting system,” in *Proc. 22nd ACM SIGKDD Int. Conf. Knowledge Discovery and Data Mining**, 2016, pp. 785–794.

[27] Ö. B. Güre, “Classification of students’ dropout status using the Random Forest method,” *Int. J. Eurasia Soc. Sci.**, vol. 15, no. 57, pp. 1401–1411, 2024.

[28] A. Siri, “Predicting students’ dropout at university using artificial neural networks,” *Ital. J. Sociol. Educ.**, vol. 7, no. 2, pp. 225–244, 2015.

[29] L. G. R. Putra, D. D. Prasetya, and Mayadi, “Student dropout prediction using Random Forest and XGBoost method,” **INTENSIF: J. Ilmiah Penelitian dan Penerapan Teknologi Sistem Informasi**, vol. 9, no. 1, pp. 147–161, 2025.

[30] D. Andrade-Girón, J. Sandívar-Rosas, W. Marín-Rodríguez, E. Susanibar-Ramírez, and E. Toro-Dextre, “Predicting student dropout based on machine learning and deep learning: A systematic review,” **EAI Endorsed Trans. Scalable Inf. Syst.**, 2023.

[31] A. Ali and M. Hassan, “A comparative study of Random Forest and XGBoost for predicting academic risk,” **Educ. Inf. Technol.**, vol. 29, no. 3, pp. 2157–2172, 2024.

[32] Y.-H. Cheng, M.-H. Shih, and C.-N. Kuo, “Early prediction of student suspension and dropout for counseling resource optimization using multilayer perceptron,” **IEEE Access**, vol. 13, 2025.

[33] J. Brownlee, *Feature Engineering and Selection: A Practical Approach for Predictive Models*. Machine Learning Mastery, 2020.

[34] “Feature Engineering: Scaling, Normalization, and Standardization,” *GeeksforGeeks*, 2025. [Online]. Available: <https://www.geeksforgeeks.org/ml-feature-scaling-part-2/>

[35] “Feature Scaling (rescaling),” *Wikipedia*, [Online]. Available: https://en.wikipedia.org/wiki/Feature_scaling